实习项目 · 最终研究汇报

公募基金本地 LLM 应用与部署研究

业务任务、运行资源与三年成本

01 个人与小组

02 权限知识库

03 公司共享 Agent

2026 年 10 月 20 日

三种部署方式，服务不同的工作范围

个人入口、公司资料与共享模型可以组合使用

方案	主要工作	配置起点	建设重点
个人 / 小组	材料、代码、表格	Spark + Qwen27	响应速度与多轮任务
权限知识库	授权检索、问答、引用	Onyx 或 Milvus 自建	员工身份与资料更新
公司 Agent	多人、多工具、长任务	DeepSeek +共享 GPU	上下文、并发与运行管理

工作要求和数据范围决定所需资源。

从前中后台的具体工作出发

模型理解材料、组织步骤，工具与人员完成后续工作

职能	具体工作	LLM 参与形成的产物
前台：投研 / 量化	读财报、整理公告、维护研究代码	比较表、事件记录、代码与说明
前台：交易支持	理解业务查询、选择数据接口	查询参数、受控 SQL 、结果解释
中台：风险 / 合规	整理风险邮件、条款与待审材料	风险字段、依据、待复核疑点
后台：运营 / IT	文件整理、异常说明、工单与测试	结构化记录、说明、代码与测试结果

每个用例都明确输入、模型动作、直接产物和后续处理。

来源：行业调研与2026年公开披露；按典型职能归纳。

公开案例展示了可复用的工作方法

材料归纳、业务查询、文案审核与接口调用

案例	模型负责什么	直接产物
富国	筛选材料、归纳内容、综合观点	知识小结与市场观点
南方	理解查询、组织参数与 SQL	统计结果与业务答复
鹏华	结合审核项理解文案	风险疑点与修改建议
易方达 Index–Hub	选择接口和参数，组织返回数据	带日期的数据答复

富国披露：相关研报工作从一周以上缩短至 3 小时以内。
鹏华披露：营销审核修改建议的最新采纳率为 91% 。

这些案例把模型产物接入了已有业务流程。

来源：富国、南方、鹏华与易方达公开披露。

两期财报和一份 CSV，形成可核对的研究产物

用同一个任务解释个人、知识库和共享服务

资料

两期财报
一份 CSV

→

模型

对齐期间与单位
决定核对步骤

→

Python / 文件工具

计算与校验
生成 Excel / 图表

→

交付

差异说明
引用与可复算文件

核对工具结果，必要时回到原文补充依据

公告提取采用同样分工：模型识别字段，程序校验，研究员接收记录。

虚构财报与 CSV 示例，用于说明模型和程序的分工。

上下文长度与并发数共同决定资源需求

总上下文包含输入和输出，计划预留 8,192 个输出 token

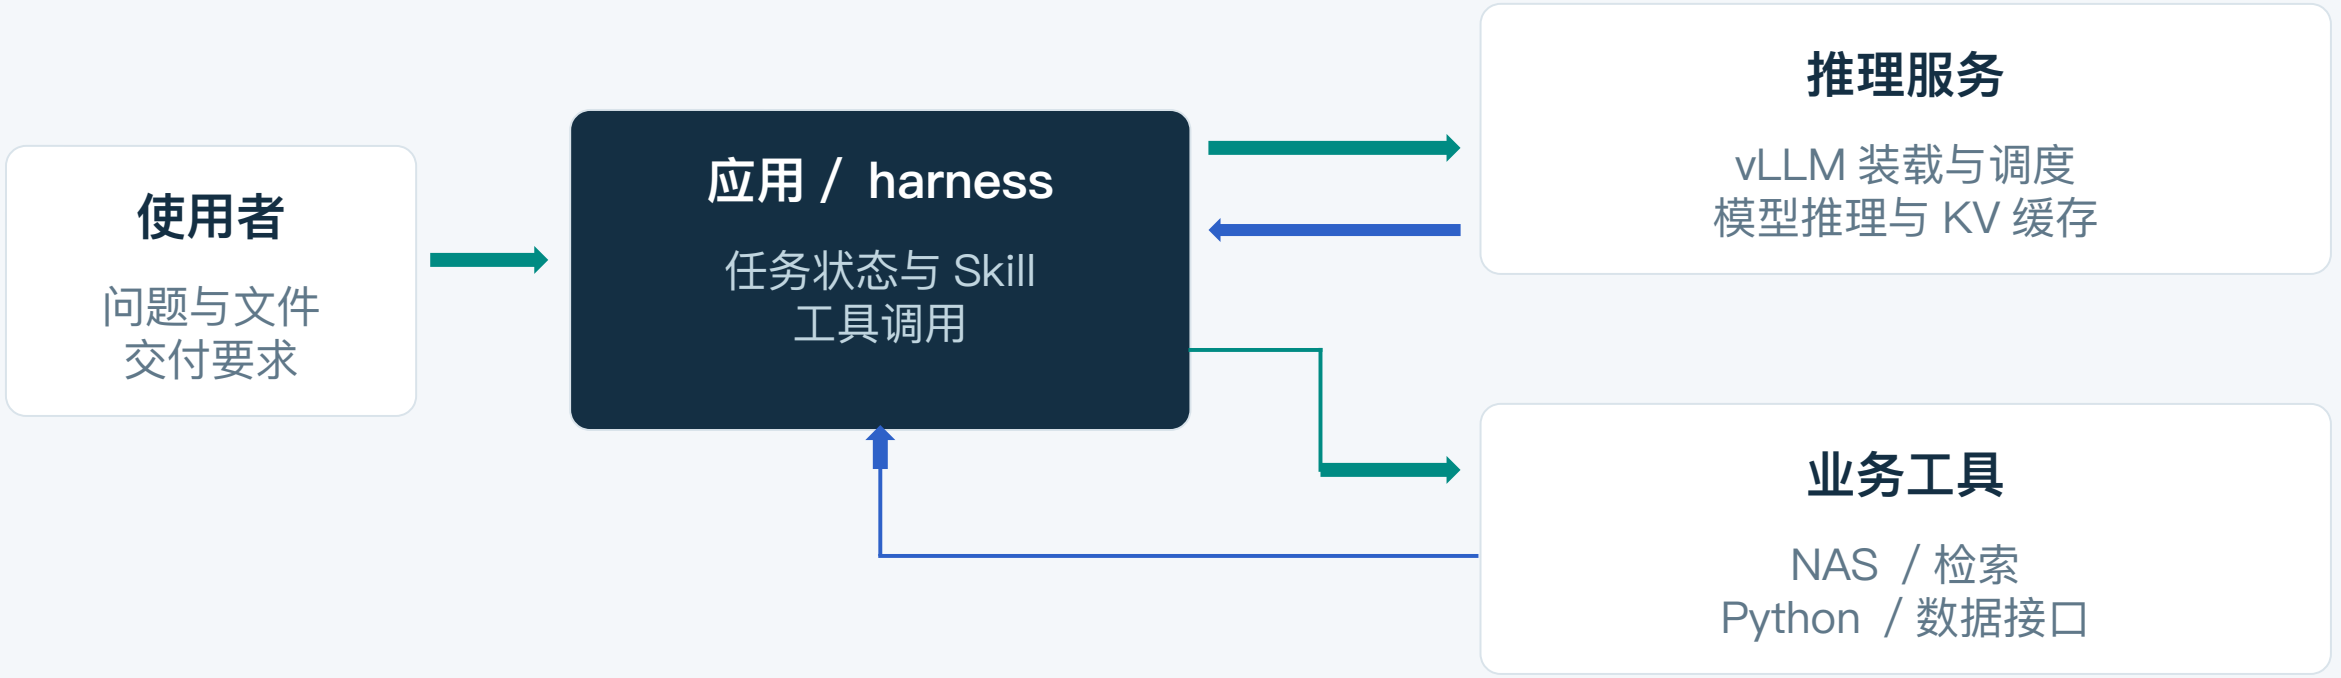
工作方式	上下文特点	主要资源
个人 Agent	长材料、工具返回、持续追加	单人生成、会话缓存
权限问答	问题＋授权片段；可继续追问	检索、输入处理、短输出
共享 Agent	多轮长任务与工具等待交错	同时生成的请求＋全部保留会话

50 个账号、 20 路生成和 40 份会话缓存，分别衡量覆盖范围、计算与存储。

512K = 524,288； 1M = 1,000,000 。二十路为公司主研究情景。

模型推理和工具执行由不同组件承担

现成应用组织多轮任务，业务方法和工具通过接口接入

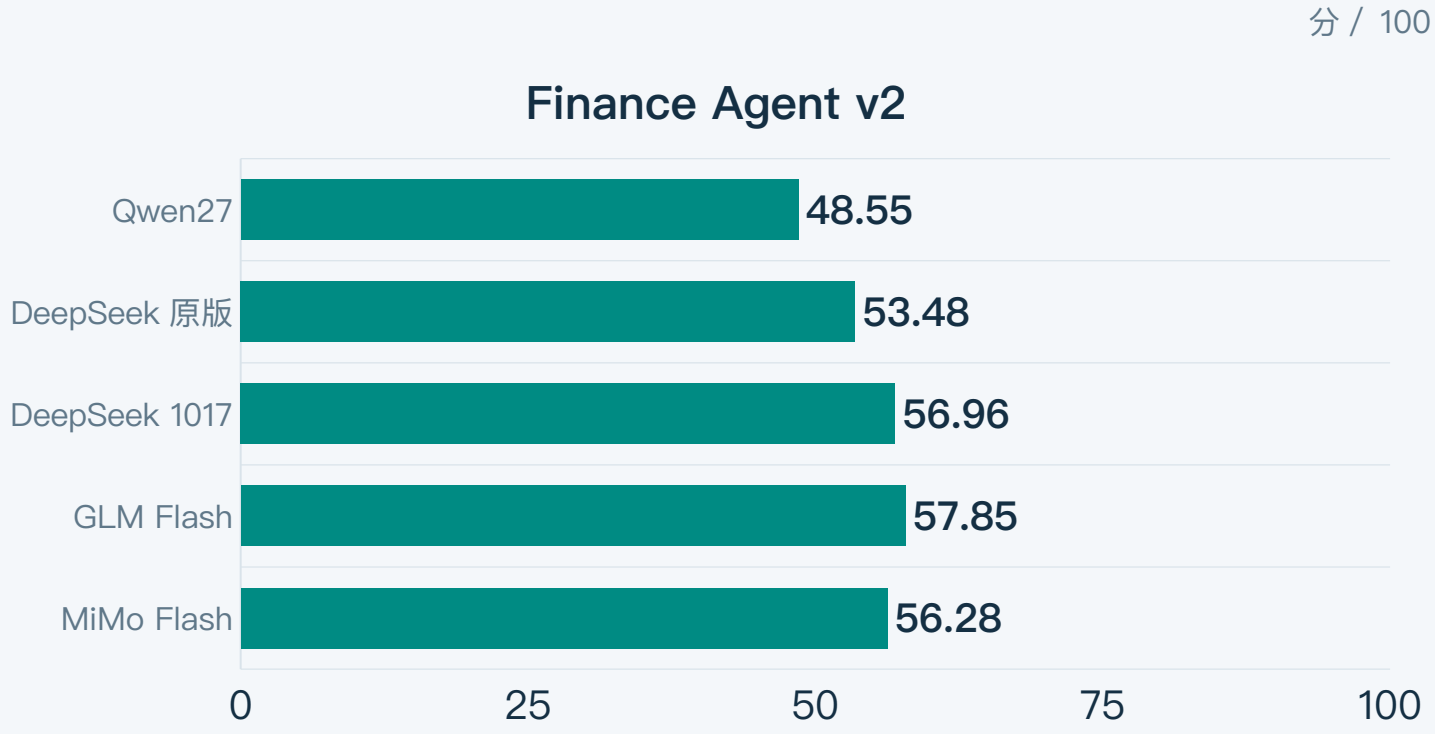


模型可以替换，业务方法、权限和计算工具继续复用。

来源：模型、serving和harness官方资料；详见软件备查页。

两条主路线分别服务个人与共享任务

Qwen27 用于个人与知识问答， DeepSeek 用于共享长任务



选型含义

个人： Qwen27 FP8 起步

共享： DeepSeek 长任务服务

对照： GLM Flash
与 MiMo Flash

Gemma 与 Kimi 另作专项比较

Finance Agent v2，作者页2026–10–18更新；指标为加权部分得分。

Spark 运行模型，员工电脑执行工具

OpenCode 调用电脑上的文件与工具，沿用员工身份

员工电脑

OpenCode / Skill
文件、 Python 、 Excel
员工身份与 NAS 权限

输入 / 工具结果





答案 / 工具调用

DGX Spark 128GB

Qwen3.8–27B
vLLM 模型接口

交付产物

比较表与图表
代码与测试
有出处的说明

输入与工具结果送给模型；工具调用和答案返回员工电脑。

性能分支为Qwen3.8–27B–FP8＋FP8 KV＋MTP3。

128GB 统一内存怎样分配

模型、草稿模型、 KV 缓存与系统共用物理内存

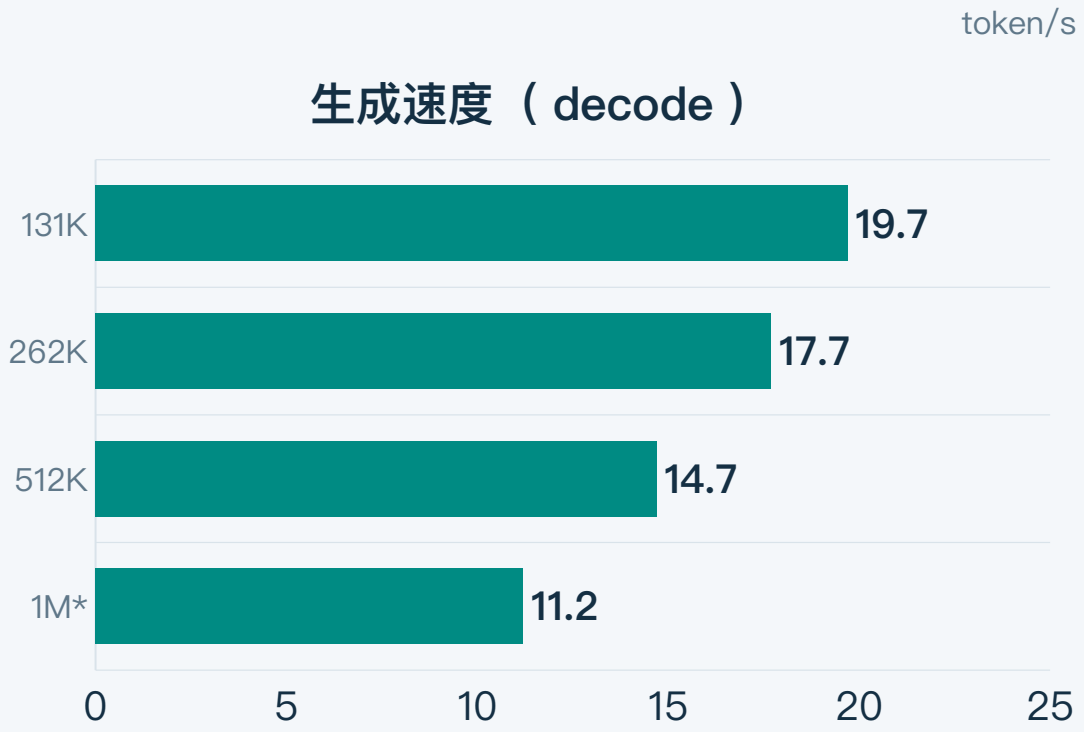
组成	测试配置 / 占用	配置含义
权重与草稿	28.47GiB	Qwen27 FP8 + MTP3
KV 预分配池	59.73GiB / 1,806,907 tokens	所有驻留会话共享
上下文设置	YaRN×4； 主模型 / 草稿均 1M	应用另预留 8K 输出
完整精度 KV 分支	同池 token 容量近似减半	单人 512K 或三人各 262K 容量参考

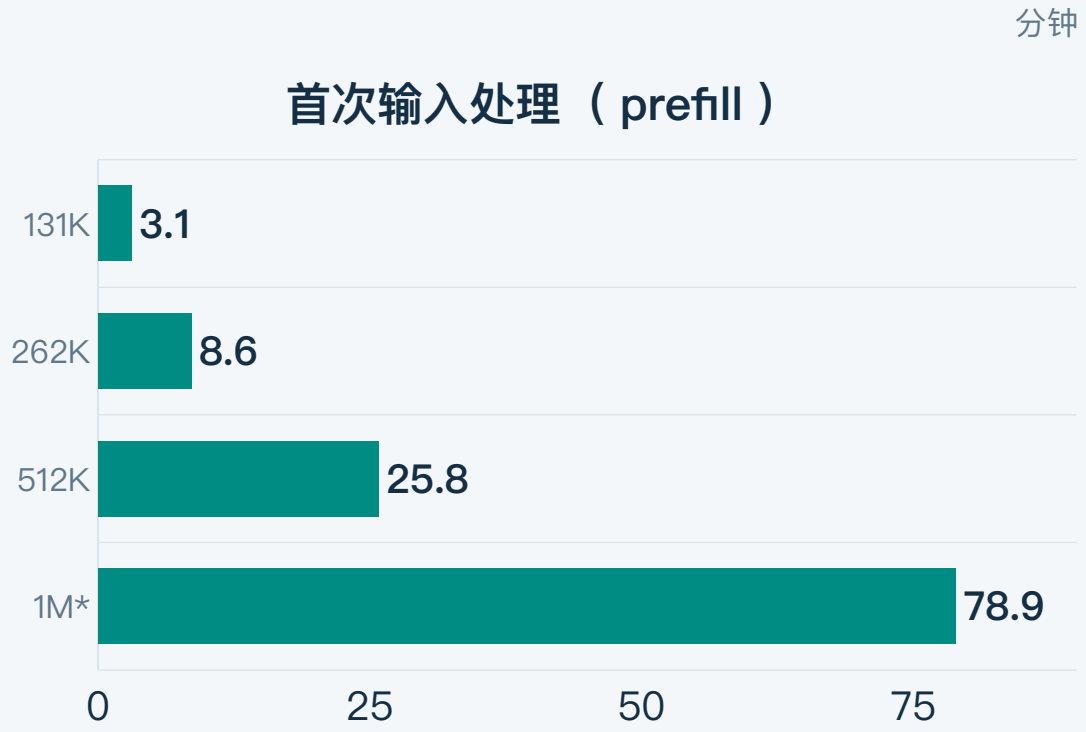
缓存块的精度和状态布局，与模型权重精度分别记录。

外部设备测试汇总；前缀缓存关闭，GPU预算0.80。

长上下文主要增加首次输入处理时间

接近用满窗口，预留 8K 输出；四档均为经验估算





实测 100K 约 20.1 token/s； 500K 约 14.8 token/s 。

外部实测＋经验估算； 1M 为外推。单人交互目标 20+ token/s 。

前缀复用省去旧输入的重复处理

两种请求的总窗口都接近 512K，旧 KV 与递推状态已在内存

新增 1K 工具结果

约 5 秒

已有前缀直接复用
处理本轮 1K 工具结果

新增 8K 工具结果

约 40 秒

已有前缀直接复用
处理本轮 8K 工具结果

系统提示和工具定义保持稳定、内容从末尾追加，更容易复用已有前缀。

5秒 / 40秒为新增prefill估算；首token等待另含队列与第一步生成。

Spark 用 NVMe 保存闲置会话状态

CPU 与 GPU 共用 128GB ， SSD 提供额外的会话存储空间



实现方式与状态要求

01　vLLM 原生 KV 卸载

02　LMCache MP 多级存储

03　按模型布局保存完整会话状态

512K 载荷 17.18GB ÷ 6GB/s ≈ 2.86 秒

CPU 缓存副本仍占同一 128GB 内存， SSD 才增加物理存储空间。

假设SSD有效6GB/s；512K全注意力KV载荷读取约2.86秒，另计递推状态与调度。

三人共享时，缓存容量和生成速度分别计算

缓存容量预留余量，速度来自三路 100K 输入实测

留余量后的可分配池

1.626M tokens

三人各 512K： 可容纳
一人 1M： 其余两人共 626K

三路 100K 输入实测

17.5 token/s

同时生成窗口内的每路均值
全段平均每路约 12.5 token/s

保留会话占用缓存，同时生成消耗算力，两者分别限制共享规模。

容量留 10% 余量；右侧速度为三路各 100K 输入、 4,096 输出。

个人首次投入约 7 万元起，按任务选择上下文

硬件、首次实施与持续运行分别计算

个人首次投入

6.8–8.2 万元

硬件 5.8–6.2 万
首次实施 1–2 万

三人共享首次投入

7.8–9.9 万元

共用同一台 Spark
增加多用户接入与检查

个人中等任务量下，三年 TCO 约 9.05 万元；技术人工按 2,500 元 / 人日估算。

硬件 / 实施为 10 月 12 日预算；三年 TCO 按 10 月 20 日中量情景。

员工按 NAS 权限查询资料，答案附原文出处

检索结果带原文位置，同一接口可供 Agent 调用

NAS

文件与权限（ACL）

→

解析与建索引

文档解析
向量与关键词索引

→

按权限检索

身份过滤后重排

→

生成回答与引用

Qwen27 ＋原文入口

检索、引用和导出都检查权限；撤权时同步更新索引与缓存。

Onyx 与自建方案，主要区别是交付和维护

两条路线采用相同的模型资源与权限验收要求

部分	Onyx Enterprise	Milvus ＋自建 RAG
入口与管理	平台搜索、问答、管理	Open WebUI ＋管理接口
资料与权限	连接器＋约定的 NAS 适配	扫描、 ACL 求值、身份同步
索引与检索	所选平台版本的索引与检索组件	Milvus 向量＋关键词检索
模型服务	Qwen27 内部端点	同一 Qwen27 内部端点
维护责任	平台方 / 集成商＋内部 IT	内部应用与运维团队

选择平台之前，先明确 NAS 连接、撤权同步和引用访问的交付范围。

Onyx企业授权按实际席位与范围询价，记为L。

短问答的吞吐与长会话的容量分别核算

四张 6000D 中三张回答、一张辅助，两台 CPU 节点负责应用与检索

项目	统一主方案
模型与辅助 GPU	3×Qwen27 回答副本＋ 1×embedding ／ reranker
应用与索引	2 台 CPU 节点，各 128GB ECC 与镜像 NVMe
20 路短问答	8K 输入＋ 600 输出；每路约 21.5—22.0 token/s （计算）
长会话缓存容量	131K： 合计 9 份； 262K： 合计 3 份
首次投入：平台 / 自建	84.5—158 万元＋ L ／ 91.5—168.5 万元

NAS 规模仍待盘点；首次入库、授权报价和运行费用单独预算。

9 月预算与条件计算， 10 月统一配置口径；性能数值为工程估算。

模型供多人共用，任务与工具环境各自保留

Hermes 组织多轮工作， Skills 保存方法， MCP 连接资料和系统



目标规模： 20 路同时生成，长会话上限按 1M 规划。

模型权重、 Engram 与会话 KV 分别计算

模型固定占用与随会话增长的状态分开计算

资源	规模	主要位置
原生 checkpoint	510.29GB	模型制品
Engram 查找表	202.76GB / 份	主机内存
其余权重	307.53GB	GPU 权重预算的起点
每个 1M 会话全局 KV	1.827GB / TP rank	参与推理的各 GPU
其他运行状态	按实际启动与图捕获预算	局部缓存、草稿、工作区

Engram 随模型实例安排； KV 随保留会话和上下文增长。

官方原生制品；Hopper缓存按固定源码与启动池核算。

八卡 H200 可容纳二十份 1M 会话

按图捕获后的较严格缓存预算估算，再预留 10% token 余量

配置	保留 20 份 / 每份上下文	保留 40 份 / 每份上下文
8×H100， TP8	约 242K	约 121K
4×H200， TP4	约 762K	约 381K
8×H200， TP8	1M （配置上限）	约 636K
8×H200，双 TP4	1M （配置上限）	约 762K

同机 TP4×DP2 可共享一份 Engram；两个独立 TP4 服务按两份计。

容量按图捕获后的预算等比例估算；生成速度另行核算。

GPU 处理当前请求， DRAM 和 SSD 保存会话状态

20 个正在生成的请求 + 20 个等待工具的请求，需保留 40 份上下文



运行方式

01　本轮结束，保存可复用状态

02　工具返回，预先将所需状态读回 GPU

03　处理新增输入，再继续生成

保留会话数决定缓存存储量，同时生成请求数决定 GPU 计算负载。

来源：AI Infra Book 8.3 / 9.5与vLLM、LMCache文档。

首 token 等待包括状态读回、排队和新增输入处理

目标吞吐、公开回放与载荷传输估算分别说明

问题	数值与统计范围
二十路生成目标	20×20 = 400 token/s 系统生成目标
公开 H200 TP8 回放	32 会话，约 1,052 token/s 总输出， p95 TTFT 2.63 秒
1M 会话：内存→ GPU	TP4 全局 KV7.31GB ； 载荷传输约 0.30 秒
SSD 经 CPU 传入 GPU	同一载荷约 1.52 秒；另计新增 prefill
20 份会话同时读回	内存→ GPU ， 总载荷 146.16GB ； 约 6.1 秒

首 token 等待＝状态读回与排队＋新增输入处理＋首次生成。

公开回放输入 140K–157K 、前缀命中约 95% ； 载荷传输带宽 24 / 6GB/s 为假设。

整机预算取决于卡型、互联和交付范围

八卡 H200 为主候选， A100 结合已有设备评估复用

GPU 与互联	CPU / 主机内存	整机预算 / 万元
8×A100 80GB SXM（翻新）	双 EPYC 7V12 / 1TB	91—102
8×H100 80GB SXM / NVSwitch	双 EPYC 9454 / 1.5TB	285—298
4×H200 NVL 141GB	双 Xeon 6710E 等级 / 1TB	161—283
8×H200 SXM 141GB / NVSwitch	双 EPYC 9454 / 1.5TB	291—304

工具集中执行时，另计 12—26 万元 CPU 节点；也可在已有终端执行。

价格核验2026-10-20；人民币为分析预算，境外挂牌不等同境内成交。

A100 方案采用 modified vLLM

沿用 vLLM 服务能力，在目标机器上取舍适配补丁

沿用 vLLM 服务能力

调度 / 缓存 / 接口

请求队列、分页状态
监控、部署与版本维护

维护必要硬件适配

算子与通信补丁

在目标机器上比较增量收益
覆盖长任务与并发负载

硬件适配借鉴 shi3z 等公开实现，服务调度、接口和维护沿用 vLLM 。

数值对应各自硬件、负载与统计范围，完整记录见备查页。

模型服务器、工具环境和运维人员共同构成服务

硬件采购之外，实施与持续运行也是成本

组成	配置 / 预算口径
模型服务器	8×H200 ； 主机 1.5TB ； GPU 整机 291–304 万元
任务执行	员工终端或集中 CPU 节点，新增 12–26 万元
应用与数据	Hermes 、 Skills / MCP 、已有授权检索接口
首次实施	公司 TCO 基准 45 技术人日， 11.25 万元
持续运维	基准 60 技术人日 / 年，另计用电、机位与软件

主方案按 20×1M 规划缓存容量，服务速度仍需用实际任务核验。

中等任务量情景，技术人工 2,500 元 / 人日；完整三年比较见成本页。

三种方式可以逐步组合

以工作范围和数据位置决定共享哪些资源

方式	获得的能力	主要投入	适合起步的任务
个人 Spark	本地文件、代码 连续会话	设备＋少量实施维护	提取、表格、脚本与测试
权限知识库	统一检索、出处 撤权同步	接入与权限 索引与平台	部门资料问答
共享 DeepSeek	较大模型 多用户工具任务	GPU 、任务环境与运行管理	复杂财报分析与多轮任务

资料检索与工具可以复用，模型服务按质量和用量扩展。

资料范围决定本地与 API 可处理的任务

权限校验、工具隔离、引用复核和版本管理贯穿工作链路

环节	实施动作
资料进入	按分类与协议确定本地 / API 路径
检索与引用	员工身份贯穿片段、下载、导出与撤权
模型与工具	固定版本，隔离目录、凭据和外发能力
输出交付	数字、引用、计算文件与测试结果一起复核
更新与运行	同一任务集回归，保留变更与处理记录

本地运行的价值包括资料与工具控制；经济性同时比较现金与人力投入。

公开规则核验2026-10-20；具体采用按数据、主体和交易条件落实。

多轮任务要计算每次提交的完整输入

8 轮任务从 100K 增长到 170K ， 缓存读取继续计费

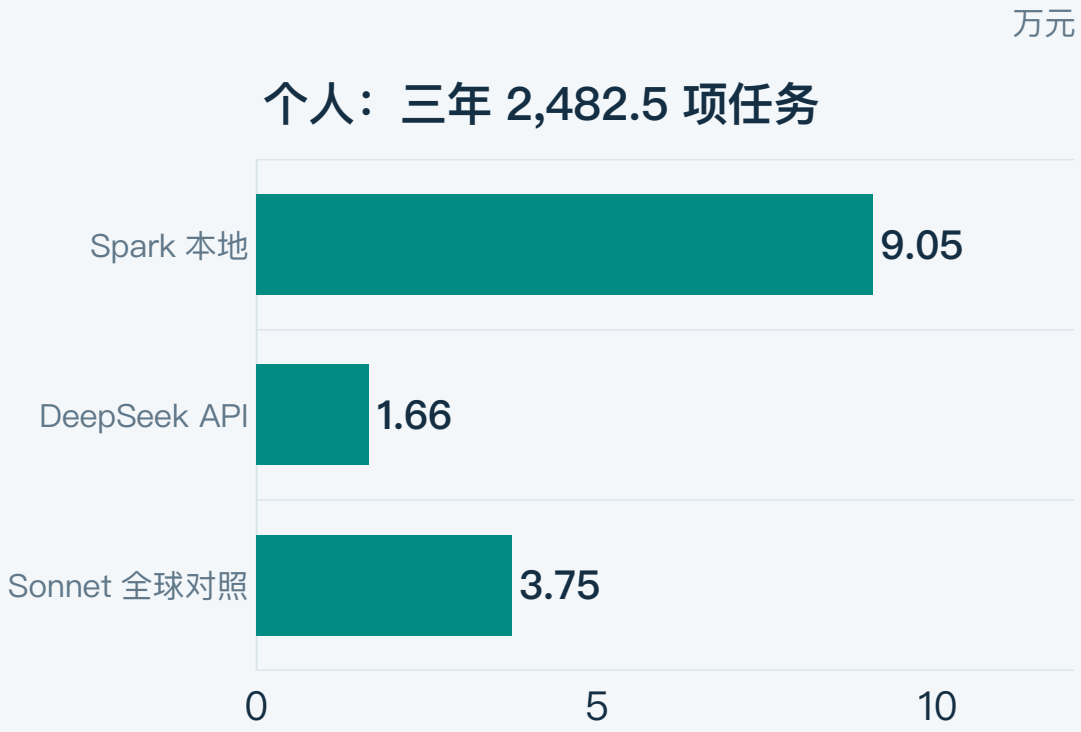
一项 8 轮任务	数量	处理方式
累计提交输入	1,080,000 tokens	分为缓存读、写或未命中
新增外部输入	156,000 tokens	已经包含在累计输入中
累计输出	16,000 tokens	含思考、工具参数与正文
DeepSeek 每计划任务 token 费	约 0.625 元	含 10% 额外执行轨迹
Sonnet5.5 每计划任务 token 费	约 9.047 元	全球对照， 1 小时缓存

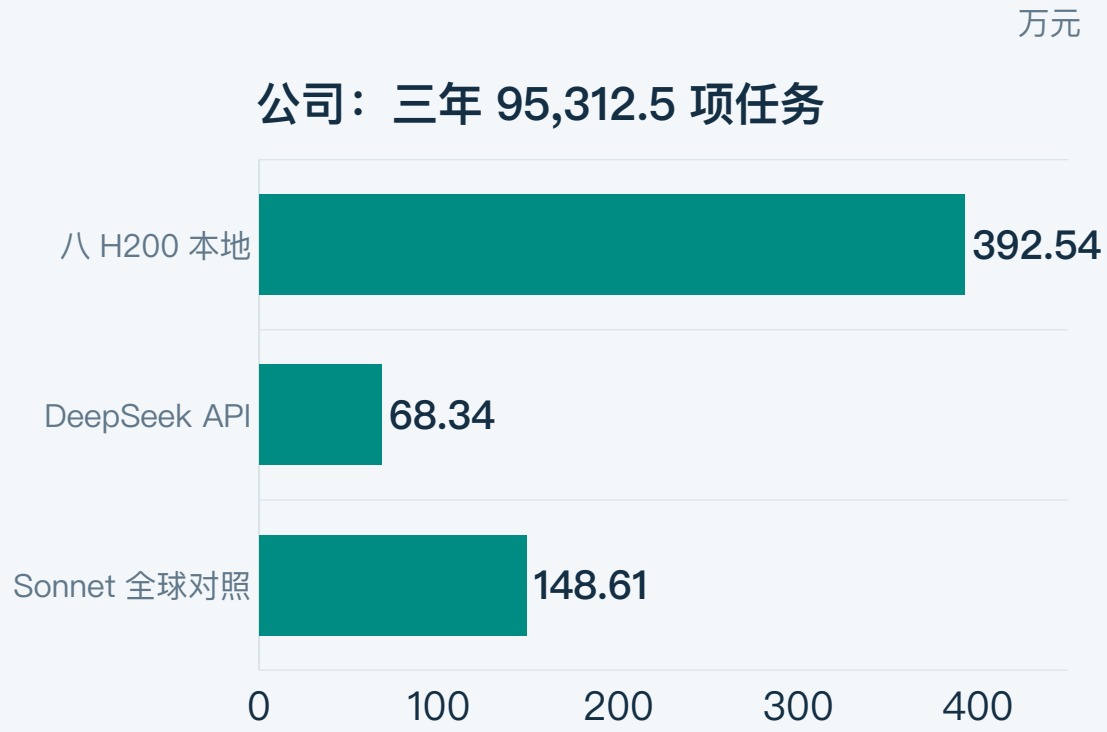
API token 费之外，实施、工具、维护与审核也计入总成本。

基准假设：可复用前缀命中率95%；汇率7.00，API token费另加6%预算准备金。

中等工作量下， API 预算低于新购本地设备

包含实施与持续运维人工；个人与公司分别比较





公司本地 GPU 采购约占三年 TCO 的 76% ，实际使用量影响固定成本的分摊。

单位万元；10/20费率与工作量假设。API资料 / 地域条件见“数据与运行”页。

使用量超过单机容量后，新增设备计入成本

按 100K–170K 多轮任务估算处理能力，比较低、中、高使用量

公司使用量	三年任务数	逐年 GPU 节点数	本地 / DeepSeek / Sonnet（万元）
低	30,000	1 → 1 → 1	391.70 / 64.26 / 89.52
中	95,312.5	1 → 1 → 1	392.54 / 68.34 / 148.61
高	237,500	1 → 2 → 2	712.78 / 77.23 / 277.25

使用量增加可以分摊固定投入；超过处理能力后，扩容费用也随之增加。

规划容量： 400 decode + 8,000 未缓存 prefill token/s； 2,000h / 年， 70% 使用预算。

公告提取与代码辅助优先启动

按公开任务证据、实施条件和出错后果安排试点

顺序 / 任务	首期技术人日	实施估算 万元	主要交付
1 公告提取	8—12	2.0—3.0	字段表、证据句与错误样例
2 代码与测试	6—10	1.5—2.5	代码变更＋独立测试
3 财报比较	12—20	3.0—5.0	计算表＋摘要与引用
4 NAS 授权问答	25—45	6.25—11.25	选定目录＋权限验收
5 材料预审（储备）	15—25	3.75—6.25	规则与审核样例

净节省工时＝原人工时间－辅助操作、复核和返工时间。

人日和时间节省均为规划输入；设备与平台统一分摊，工时价值与现金分开。

公开评测用于筛选，业务验收对应具体产物

公开结果在同一基准内比较，业务验收逐项检查产物与过程

公开证据	对本项目的含义	后续业务验收
字段提取流程	短文提取适合起步，长列表易漏	关键字段、数量、单位、证据
金融研究与多文档 QA	模型筛选与对照： Qwen 、 DeepSeek 、 GLM	期间口径、事实覆盖、引用
终端与代码任务	以测试验证代码产物	既有测试、边界情况、重复运行
多步骤任务	结果与执行过程分别检查	权限、只读边界、工具记录

已准备 12 个虚构初始任务；运行后将人工时间与资源消耗计入 TCO 。

公开基准各有任务与执行设置，比较时保留版本和指标名称。

按业务依赖逐步扩展本地 LLM 应用

从个人可核对任务开始，逐步连接共享资料和模型

第 1–2 周

公告提取＋代码辅助

字段、测试、人工时间

→

第 3–5 周

财报比较与摘要

计算文件、口径、引用

→

第 5–8 周

部门 NAS 授权问答

身份、撤权、运维交接

用试点质量、等待时间和三年成本，确定共享 GPU 的配置与规模。

时间为项目启动后的规划；技术资源与业务验收按各方案落实。

主模型与备选分别记录资源需求和许可条件

按用途比较候选模型，具体制品以固定记录为准

模型路线	主要用途	资源 / 许可要点
Qwen3.8–27B / Qwen3.6–35B–A3B	个人与知识库	Apache 2.0； 本稿主用 27B FP8
Gemma 4 31B / 26B–A4B	来源不同的个人备选	Apache 2.0； 中文与工具任务逐项比较
DeepSeek V4.1 Flash / 1017	共享长任务	MIT； 原生制品约 510.29GB
GLM5.3 Flash / 主模型	共享金融任务对照	Flash MIT； 主模型自定义条件
MiMo V2.6 Flash / Pro	共享能力与资源对照	固定制品及 MIT 声明、实现依赖分别记录
Kimi K3	高能力研究参照	较大权重；内部使用与对外服务条款分别核对

新增模型使用同一组任务比较，并记录制品、引擎和许可。

许可核验2026–10–20；自定义许可按使用主体、服务方式和触发条件解释。

软件分别承担工作入口、任务组织与模型服务

界面、工作流、 Agent 执行和推理服务分别比较

类别	代表项目	主要作用
员工工作台	Open WebUI / LobeHub Cherry Studio	聊天、文件与模型入口
企业知识库	Onyx / RAGFlow / Milvus 自建	资料、索引、权限与引用
固定流程	Dify / n8n / Flowise	串联重复步骤与业务系统
通用 Agent	Hermes / OpenClaw OpenCode / pi	多轮执行、 Skill 和工具
GPU 服务	vLLM / SGLang	模型、调度、缓存与并行
特定硬件	MLX / llama.cpp KTransformers	Apple 或 CPU/GPU 混合资源

按工作职责选择产品，许可与接口按具体版本核对。

研究资料与参数截至 2026 年 10 月 20 日，出处及说明见讲者备注。

单台 GB10 的输入长度、首次等待与生成速度

FP8 权重 + FP8 KV， MTP3， 随机 token， 前缀缓存关闭

输入 token	输出 token	TTFT 秒	prefill token/s	decode token/s
1,024	2,048	0.6	1,876.1	20.53
50,000	2,048	63.1	795.1	21.01
100,000	2,048	144.8	691.7	20.11
300,000	2,048	658.9	455.6	17.23
500,000	2,048	1,470.1	340.3	14.82
999,936	64	4,815.8	207.68	9.83 （短段）

YaRN×4；主模型与草稿上限均 1M 。 1M 样本用于容量验证。

用户提供的外部测试汇总；具体模型与测试环境见知识库记录。

权限、索引和费用按同一交付范围核对

文件规模示例用于容量规划，实际 NAS 仍需盘点

项目	核对内容
身份与 ACL	继承、用户组、撤权、停用、直接接口调用
文档解析	Word / PDF / PPT / Excel，保留页码、表格、单位和版本
检索与回答	相关内容召回、引用、无答案与越权场景
完整精度 KV	每卡 38.6GB 池； 131K 合计 9 份， 262K 合计 3 份
实施人日	Onyx42—68 / 自建 70—110； 2,500 元 / 人日
额外预算	企业授权 L 、 NAS 增容、完整 HA 和持续运行

试点先接一个部门的有限目录，平台交付按相同权限案例验收。

已分配缓存池与图捕获后预算分别记录

主稿按较严格预算等比例缩减，再留 10% token 空间

公开配置	已分配 KV / 卡	实例 token 池	严格预算 / 卡
H100 TP8	12.36GiB	6.435M	10.34GiB
H200 TP4	35.16GiB	18.327M	32.49GiB
H200 TP8	62.86GiB	29.498M	60.20GiB

每会话容量≈实例池 × 严格预算 / 已分配预算 ×90%÷ 保留会话数。

性能比较保留硬件、输入与计时范围

Tokha 同机消融衡量既有 vLLM 适配基线之上的增量

实现与硬件	单路 token/s	系统总输出 token/s
shi3z / 4×A100 PCIe	代码 50–53； MTP 82–93	64 路端到端 167.5；引擎峰值 475.6
modified vLLM / 8×A100 SXM	110–140， DSpark5	32 并发 1,040–1,379
modified vLLM / 8×A800 SXM	约 115	128 并发约 3,040

八 A800 同机两项增量： 2,842.48 → 2,926.08 → 2,970.50 （约 +4.5% ）。

来源：作者项目、keplerzip、Tokha233；数值对应各自的硬件与负载。

API 费率、工作量和人工假设分别记录

按 10 月 20 日官方费率计算，三年同价作为基准情景

输入	基准值
DeepSeek 低峰 未命中 / 命中 / 输出	0.15 / 0.003 / 0.60；高峰 ×2
Sonnet 输入 / 1h 写 / 读 / 输出	2.00 / 4.00 / 0.10 / 10.00
个人任务量	750 → 825 → 907.5 项 / 年
公司任务量	25,000 → 31,250 → 39,062.5 项 / 年
技术资源 / 分析师工时价值	2,500 元 / 人日； 150 元 / 小时
公司高量扩容	50,000 → 75,000 → 112,500 项；节点 1 → 2 → 2

每轮输出从 2K 变为 8K 时，公司中量情景需扩容，三年约 720.83 万元。

费率USD / 百万tokens；CNY汇率7.00与6%的API预算准备金均为假设。

原始资料与可复算结果

公开版本、原始数据和测算假设随知识库保存

01 AI Infra Book
github.com

02 vLLM KV卸载指南
docs.vllm.ai

03 LMCache多级存储
docs.lmcache.ai

04 Finance Agent v2
www.vals.ai

05 ExtractBench作者数据
github.com

06 DeepSeek API计费
api-docs.deepseek.com

07 A800同机消融
github.com

08 本项目发布资料
github.com