实习项目最终汇报

大语言模型在公募基金工作中的应用

工作示例、三套部署方案与成本

01

怎样使用

02

怎样部署

03

投入与收益

2026 年 10 月 22 日

各岗位可以从哪些工作开始

前台：投研与量化

比较财报、整理公告、维护研究代码

交付：比较表、事件记录、代码与测试

中台：风险与合规

核对风险材料、查找条款、预审文案

交付：风险字段、规则出处、待处理问题

后台：运营与 IT

整理异常、查询流程、处理工单

交付：异常说明、操作步骤、脚本与测试

一个财报比较任务

比较两期收入，按可比口径计算同比，生成 Excel 并标出依据。

提供的材料

2025 年报：收入 120 百万元

2024 原披露：收入 90 百万元

年报附注： 2024 重述后为 100 百万元

预期比较表

年份 / 指标	可比数值	依据
2024 收入	100 百万元	重述附注
2025 收入	120 百万元	2025 年报
同比增长	20%	(120−100)÷100

交付文件：收入比较 .xlsx 、比较说明 .md

虚构示例，来自评价包 QA-01 ； 右侧为预期产物。

大语言模型怎样利用我们提供的资料

大语言模型（LLM）根据看到的内容生成回答或操作指令。
公司当前的资料，要随任务提供给它，或让它通过资料查询工具取得。

资料

两期财报、重述附注和 CSV

要求

采用可比口径，解释变化

交付

Excel 、算式、出处及待核对项

具体要求示例

“请按重述后的 2024 年收入计算同比。原披露值单独保留，缺少依据的地方列为待核对项。”

模型读材料，程序算数字，人员核对结论

原披露口径

(120−90)÷90

33.3%

重述后的可比口径

(120−100)÷100

20.0%

模型

找到“ 2024 年重述为 100” 的附注

程序

使用确认后的数值计算

人员

核对出处，并确认解释是否成立

虚构财报示例；两种算法的差别来自比较基期。

行业中的两种实际做法

富国：研报材料整理

阅读与筛选材料，形成小结和观点

一周以上 → 3 小时以内

相关研报工作耗时

鹏华：营销文案审核

结合审核规则，标出疑点并提出修改意见

91%

最新修改建议采纳率

公司公开披露的项目效果，指标口径不同。

文字问答与 Agent 任务

“比较这两期财报，并把结果做成 Excel 。”

只要求文字回答
得到解释或一段代码
员工再复制内容
运行代码、整理文件

Agent 持续执行

01	02	03	04
读取财报	选择口径	调用 Python 执行计算	核对结果 保存 Excel

Agent 交付：比较表＋说明＋计算过程

Skill 用一份说明保存固定做法，例如财报比较步骤； MCP 让应用以统一方式调用现有工具，例如查询公司资料。

三种使用范围，对应三套方案

01

个人 / 小组助手

处理自己的文件与表格
编写和修改代码

DGX Spark + Qwen27

一人优先，也可由小组共享

02

公司知识库

查询公司文件盘（NAS）
按权限回答，并给出出处

Onyx 或 Milvus 自建

重点是资料解析、权限和更新

03

公司共享 Agent

多人开展分析与计算
生成各自的工作文件

DeepSeek +共享服务器

重点是长会话、并发和工具环境

个人助手怎样完成一次任务

员工提出任务

读取当前目录两期财报与 CSV ， 采用重述口径，生成收入比较表并保留计算代码。

员工

选定目录，提出要求

OpenCode + Qwen

读文件、调用工具、检查结果

员工

打开产物，核对数字与引用

预期文件与内容

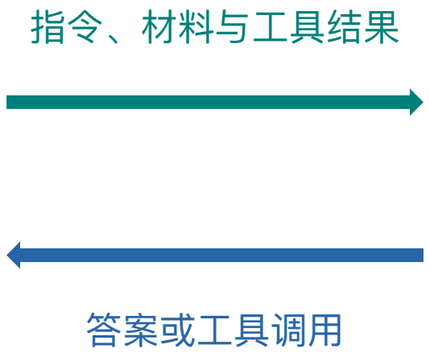
收入比较 .xlsx	原值、可比值、增幅和出处
比较说明 .md	变化说明与待核对事项
计算脚本 .py	可再次执行的计算步骤

操作流程设计；示例文件使用虚构财报数据。

一台 Spark 运行模型，电脑执行文件工具

员工电脑

OpenCode 工作入口
文件、 Python 与 Excel



DGX Spark

128GB 内存、 4TB SSD
Qwen3.8–27B 模型

硬件约 5.8–6.2 万元

vLLM 负责模型运行和请求调度；日常使用通过 OpenCode 完成。

硬件预算沿用10月12日研究，含原预算准备；软件按10月20日研究。

上下文是模型本轮能看到的材料

任务要求 + 财报与附注 + 此前对话 + 工具计算结果 + 本轮输出

一次长任务会不断加入新内容。前面的信息被压缩或移除后，后续判断只能使用仍保留的部分。

131K / 262K

基础档

512K

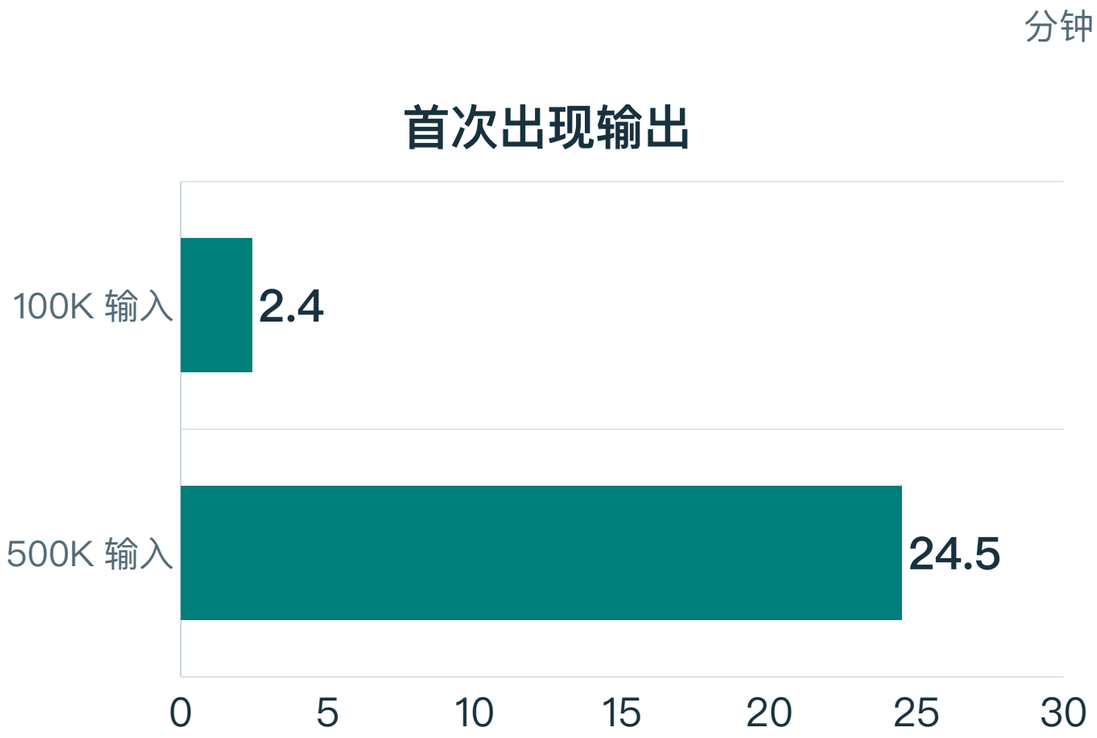
个人长任务重点

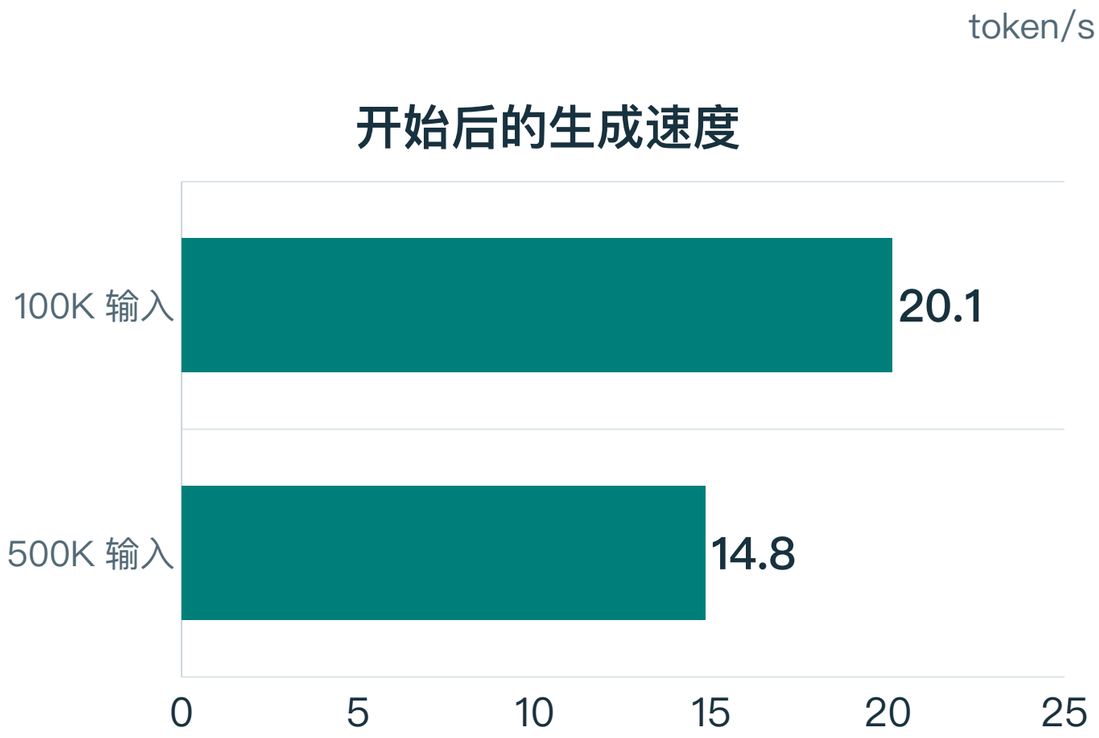
1M

更长任务的容量目标

K 约为千、 M 为百万； token 是模型计量文字的单位。总窗口同时包含输入与输出。

Spark 处理长材料要等多久





生成 500 个 token，纯输出约 25–34 秒。1M 容量测试首次等待约 80 分钟（仅输出 64 token）。

单 Spark 外部测试，随机 token 输入，未使用前缀缓存；完整配置见备查。

继续同一项任务，可以复用已处理的内容

同一份财报已经读过，本轮只追加新的工具结果。

已处理内容

财报、附注、先前对话与计算结果

→

本轮新增

一段新的工具结果

旧缓存不可用

重新处理接近 512K 输入

约 26 分钟（估算）

旧内容可复用

只处理追加的工具结果

新增 1K 约 5 秒；新增 8K 约 40 秒

图中比较的是本轮处理输入所需的时间，之后还要生成回答。

图中为输入处理时间估算；右侧假设旧内容的处理结果可完整复用。

暂停的长任务，怎样保存和继续

一名同事上午分析 A 公司，下午转做 B 公司。返回 A 项目时，已有内容可从缓存续接。

01

正在工作
内存保存当前任务状态

02

暂时离开
把已算好的中间结果存到 SSD

03

继续工作
从 SSD 读回中间结果
再处理新内容

聊天记录

保留问题和回答的文字

模型缓存

保留模型读材料时已算好的中间结果

部署设计：SSD缓存尚未在本次Spark外部测试中启用。

个人独占与三人共享怎样选择

一人使用

6.8–8.2 万元

硬件＋首次部署

三人共享

7.8–9.9 万元

共用设备，增加多用户接入

可保留多少内容	预留余量后约 1.6M token ，可容纳三份 512K 会话。
同时用起来多快	三路 100K 测试：共同生成时每路约 17.5 token/s 。
怎样安排使用	长材料首次处理排队；单人交互优先，共享任务错峰。

首次投入为硬件＋实施预算；速度为三路 100K 输入的外部实测，容量与速度分别统计。

公司知识库：按权限找资料，再回答

“现行申请限额是多少？依据哪份制度？”

01 识别员工身份 → 02 筛选有权资料 → 03 检索现行条款 → 04 回答并给出出处

检索到的制度

旧版：申请限额 2 万元
现行版：限额 3 万元
7 月 1 日起生效

预期答复

现行限额为 3 万元。依据《示例制度 2026 版》，自 2026 年 7 月 1 日起执行。

受限项目文件不进入无权限员工的检索结果，也不向其显示文件名或片段。

虚构制度示例；员工权限在检索前生效，打开原文时再次校验。

知识库的两条建设路线

Onyx Enterprise	Milvus + 自建服务
采购企业知识平台	**内部开发并维护**
已有搜索、问答和管理功能	Open WebUI 入口， Milvus 检索， Qwen 回答
对接 NAS 及员工身份，验收文档解析与权限同步	开发文件解析、权限过滤、更新与撤权流程
供应商 / 集成商 + 内部 IT 维护	内部应用与运维团队维护

检查：有权能查、无权不返回、改版后引用新版、撤权后查不到。引用能打开对应原文。

Onyx企业授权按范围询价；具体NAS接入与权限同步属于实施交付项。

知识库需要什么设备，多久能答完

设备组成

4×RTX PRO 6000D 84GB
3 张卡运行 Qwen27 回答问题
1 张卡处理检索，另配 2 台 CPU 服务器

20 人短问答的计算示例

20 个短问题同时提交
最后一位约 37 秒开始收到回答
整批约 65 秒完成

平台路线 约 85–158 万元＋企业授权

自建路线 约 92–169 万元

本页预算对应上述完整硬件配置。资料可先接入一个部门目录，再逐步扩展。

工程估算：每问 8K 输入、 600 输出；非设备实测。首次费用沿用已归档预算，平台授权另询。

多人共用模型，分别完成项目工作

团队任务：比较多家公司的收入变化，汇总成分析材料。

研究员提出任务	量化同事运行工具	负责人查看产物
比较多家公司的财报	读取授权数据并执行计算脚本	汇总获授权的比较表与证据
返回各自项目的比较表与说明	返回计算结果、代码与测试	形成跨公司分析材料

共享端暂定 DeepSeek-V4.1-Flash ，供多人处理多材料分析和工具任务。

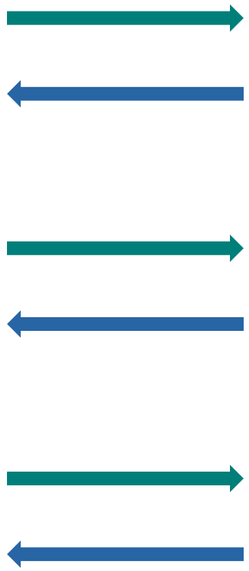
较大的模型集中运行，员工无需各自购置服务器；个人 Qwen 仍可处理日常文件任务。

模型共享，文件和权限按员工分开

研究员 A： 财报比较

量化同事 B： 数据清洗

运营同事 C： 异常汇总



共享 DeepSeek 模型服务

理解当前任务内容
返回答案或工具调用

各自的工具与产物

按身份查询 NAS

独立目录运行 Python

产物保存回各自项目

Hermes 负责组织任务；模型判断下一步，工具执行文件操作和计算。

长任务交错运行，空闲会话怎样保存

同事 A	读取资料	生成分析	等待计算	继续生成
同事 B	生成分析	等待工具	继续生成	保存文件
同事 C	等待资料	生成分析	调用工具	继续生成

同时生成 20 路，与保存 40 份长会话，是两项不同的资源需求。

显卡内存

正在处理的会话

主机内存

近期继续的会话

SSD

较久不用的会话

部署设计；缓存读回减少旧内容重算，当前请求仍要处理新增输入并生成输出。

20 份长会话，对应哪些服务器选择

8×H100	4×H200	8×H200
每份约 242K	**每份约 762K**	**每份 1M**
约 285–298 万元	约 161–283 万元	约 291–304 万元

A100 备选： 8 卡翻新整机约 91–102 万元。已有设备可评估复用，用适配后的 vLLM 运行模型。

八卡 H200 用于研究 20 份 1M 长会话； A100 方案侧重已有设备复用与较低购置预算。

20 份会话的缓存容量估算，已预留余量；预算沿用 10 月 12 日完整整机研究。

20 人共享服务的响应目标

20 人同时生成

目标每人 20 token/s

500 个输出 token 约 25 秒

第一段何时出现

新资料处理、缓存读回和排队都会形成等待。

为什么工具任务还要时间

文件读取、数据查询和计算也需要时间。

公开 H200 回放： 32 路，约 157K 输入、 95% 前缀命中； 95% 的请求约 2.6 秒内开始输出。

目标与参照分开：公开回放约 157K 输入、 95% 前缀命中；满 1M 速度待在目标设备验证。

公司共享方案的设备与维护投入

模型服务器	**291–304 万元**	8×H200 ， 含主机内存与互联
工具服务器	**12–26 万元**	文件处理、 Python 和业务接口
首次部署	**约 11 万元**	应用接入、隔离、监控与检查
持续技术维护	**约 15 万元 / 年**	升级、故障处理，检查原有任务是否正常

A100 使用适配后的 vLLM 模型服务，沿用现成的请求管理、监控与接口。

技术人工按 2,500 元 / 人日估算；设备为研究预算，采购按具体 SKU 、供方与准入核查。

本地部署与 API： 资料在哪里处理

本地部署

资料与工具留在内部，模型运行在自有设备

投入设备、部署与持续运行资源

调用 API

把获准内容发给供应商模型
再接收结果

支付模型调用费，继续维护本地应用与工具

内部受限材料：按机构批准的数据处理方式部署。

公开财报与获准资料：可以比较本地和 API 的完整成本。

API比较使用公开或符合服务条款且获准的材料；Sonnet全球价格参照置于附录。

一次分析可能调用模型很多轮

1. 读取材料
2. 核对口径
3. 调用工具
4. 计算与检查
5. 补充资料
6. 修订产物
7. 复核引用
8. 整理输出

约 0.63 元 / 项

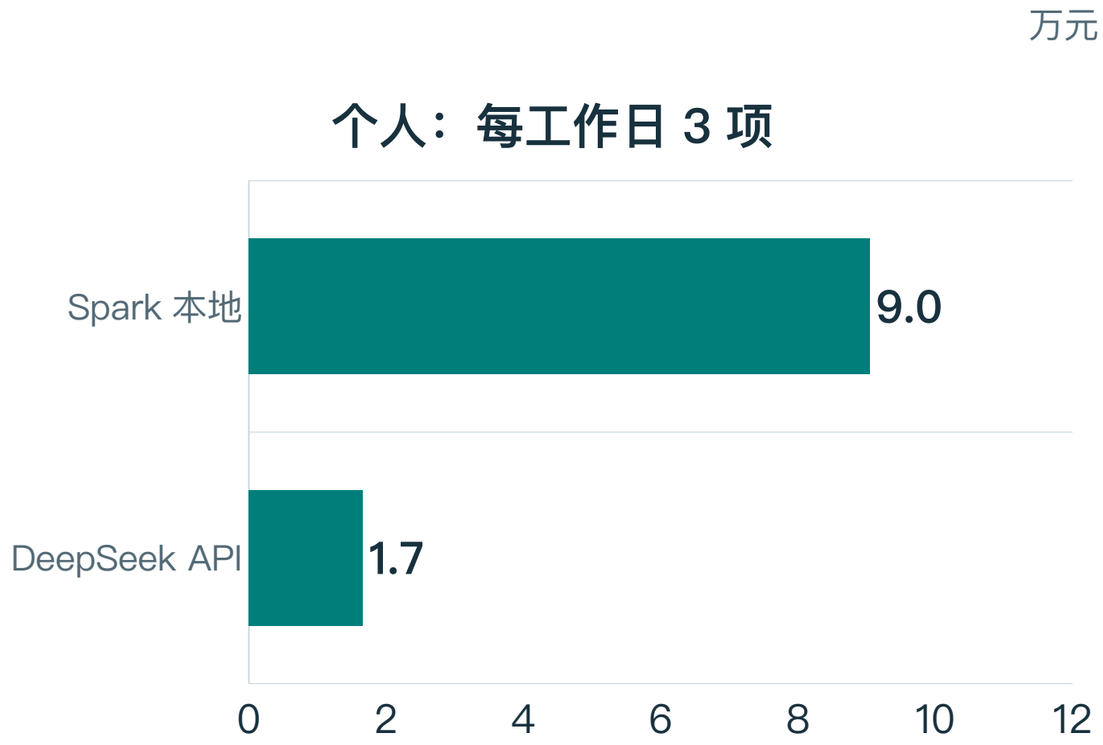
DeepSeek 8 轮任务示例
输入由 100K 增加到 170K
每轮输出 2K

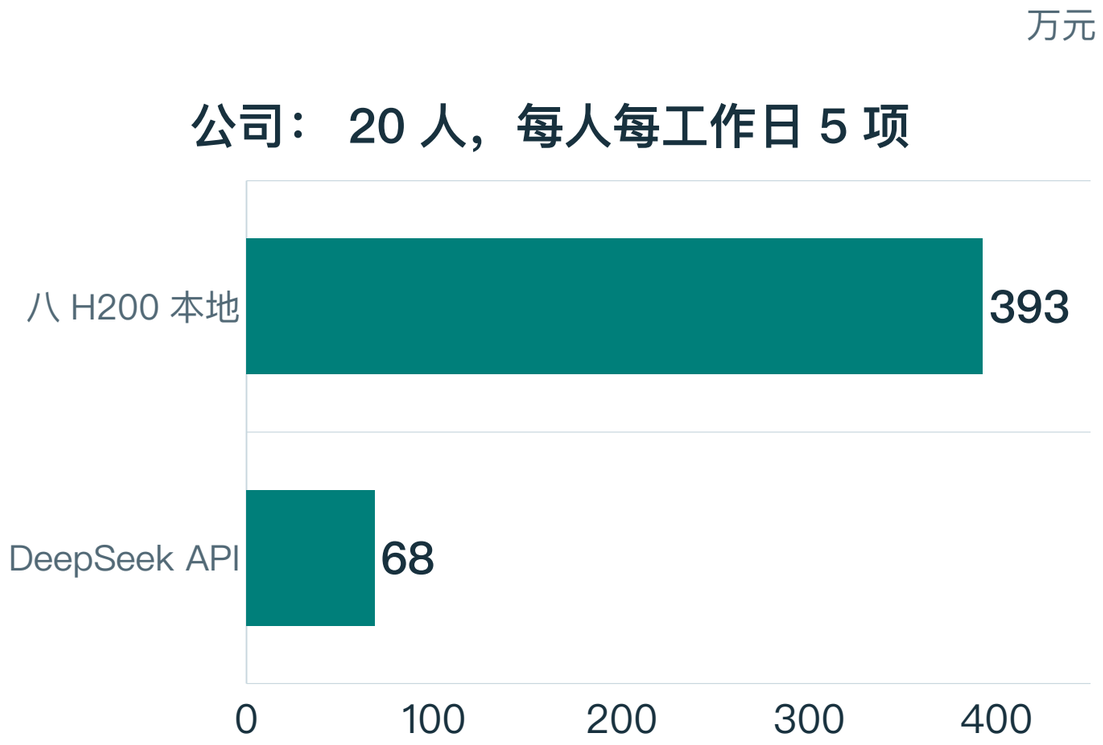
每轮输入含已积累内容；命中缓存的重复部分按缓存费率收费。

完整成本还包括：工作入口、文件工具、部署与维护人员。

10月20日费率；可复用前缀命中率95%，额外重跑任务按10%计；汇率7.00，另加6%API预算准备金。

三年完整投入：新购本地与 API

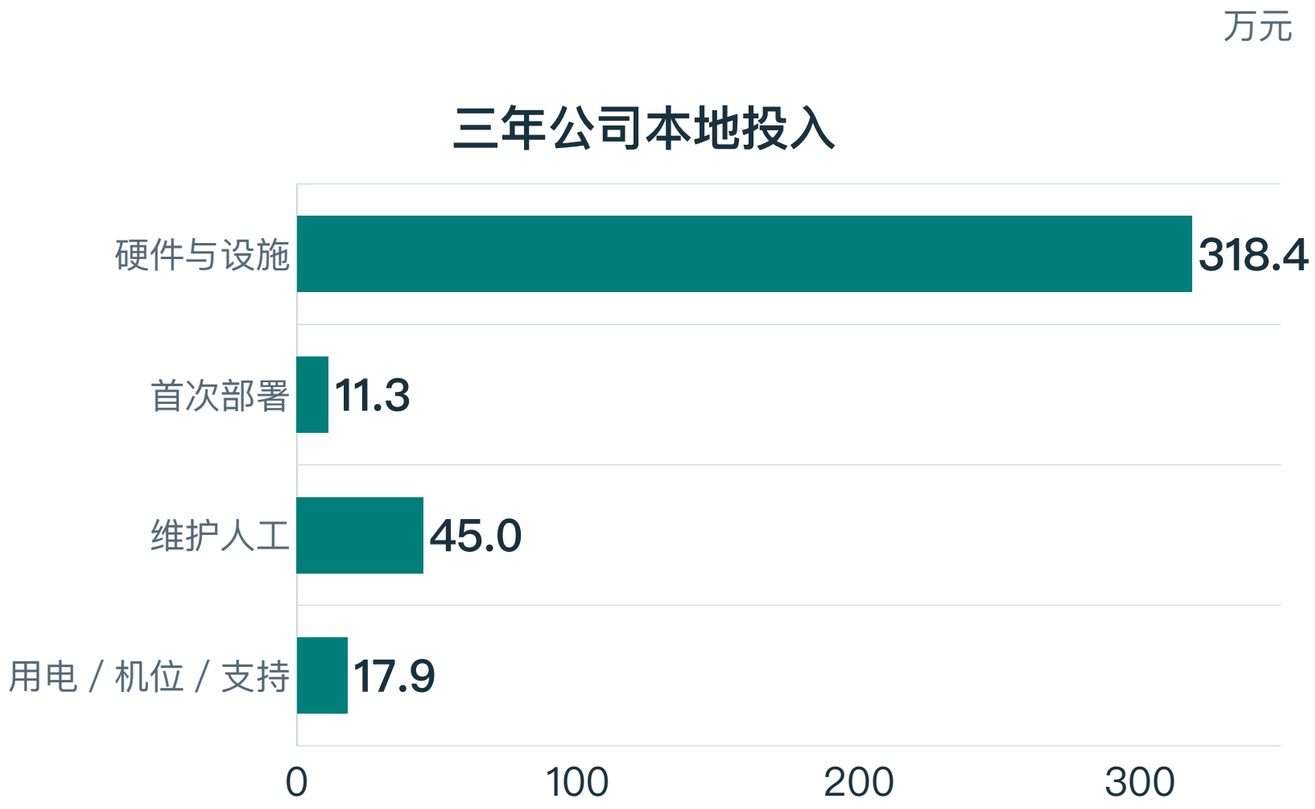




每年 250 个工作日；个人用量年增 10% ，公司年增 25% 。预算含技术实施、维护与工具费用。

统一任务用量预算；含实施与维护人工，采用10月20日费率与已归档硬件预算。

公司本地成本主要来自硬件与维护



三年预算，包含模型与工具服务器、部署、技术维护和运行费用。

硬件与设施包括

模型整机、工具服务器、首次机房接入。

技术维护包括

日常监控、故障处理、升级后检查。

运行费用包括

用电、机位和软件支持。

使用量增加后，也要计算扩容

中等使用量

20 人，首年每人每工作日 5 项

三年约 9.5 万项

GPU 节点： 1 → 1 → 1

本地约 393 万； API 约 68 万

高使用量

20 人，首年每人每工作日 10 项

三年约 23.8 万项

GPU 节点： 1 → 2 → 2

本地约 713 万； API 约 77 万

高用量情景从第二年增加一台 GPU 服务器，三年本地预算升至约 713 万元。

每年 250 个工作日；中量年增 25%，高量年增 50%；按 100K–170K 多轮任务规划容量。

首批任务优先选择容易核对的产物

虚构公告原文

“10 月 6 日签署 1.20 亿元供货合同，
10 月 8 日公告，尚未履行完毕。”

事件日	10 月 6 日
公告日	10 月 8 日
金额	120,000,000 元
状态	已签署，未履行完毕

试点顺序

先做：公告提取、代码与测试

随后：财报比较与摘要

再接：部门 NAS 授权问答

储备：材料预审与规则检查

示例公告来自虚构评价任务 NER-01；未运行模型。

收益记录：一个工时计算示例

原人工流程

90 分钟 / 项

使用助手后

操作编辑 25 分钟＋复核返工 20 分钟

净节省 45 分钟 / 项

每月 30 项，释放约 22.5 小时研究时间。

记录所有失败与返工

检查关键数字和出处

同时记录等待与人员操作时间

示例工作量与时间假设，非已实现收益；分析师工时价值按 150 元 / 小时。

下一阶段的三个交付物

第 1–2 周

公告字段＋代码测试

业务：给样例、核对结果
技术：搭入口、工具与测试

第 3–5 周

财报比较包

Excel 、计算文件、说明与引用
记录人工操作、复核和等待

第 5–8 周

部门 NAS 知识问答

接入选定目录与员工身份
检查有权、无权、改版和撤权

个人助手处理手边文件；知识库提供授权资料；共享助手承接多人任务。先从公告提取与代码测试开始。

备查：模型与公开金融评测

模型	Finance Agent v2	本研究用途
Qwen3.8–27B	48.55	个人与知识问答
DeepSeek V4.1 Flash 原版	53.48	既有共享方案及性能测试所用版本
DeepSeek V4.1 Flash 1017	56.96	开放权重升级候选
GLM5.3 Flash	57.85	金融任务能力对照
MiMo V2.6 Flash	56.28	共享能力与资源对照

Qwen： Apache 2.0； DeepSeek 及 GLM Flash： MIT 。其他候选与完整许可条件见知识库。

作者榜单10月18日更新，10月20日归档；原版与1017版的成绩和性能分别记录。

备查： Spark 实测与上下文

输入 token	首个输出等待	生成 token/s	样本说明
1,024	0.6 秒	20.53	3 次
50,000	63.1 秒	21.01	2 次
100,000	144.8 秒	20.11	2 次
300,000	658.9 秒	17.23	1 次
500,000	1,470.1 秒	14.82	1 次
999,936	4,815.8 秒	9.83	仅 64 输出，容量样本

三路 100K： 共同生成窗口每路 17.47 token/s； 整个生成阶段平均每路 12.45 token/s 。

来自用户提供的外部测试汇总；具体版本和方法保留在知识库。

备查：知识库的交付范围与预算

项目	方案输入
GPU 与 CPU 硬件	合计 74—141 万元
Onyx 首次	84.5—158 万元＋企业授权 L
自建首次	91.5—168.5 万元
短问答响应	20 路， 8K 输入＋ 600 输出，整批 65.3 秒（估算）
长会话容量	131K 合计 9 份； 262K 合计 3 份（估算）
权限检查	目录继承、用户组、停用、撤权、引用下载与导出

回答模型 Qwen27 FP8 ， KV 完整精度；额外 NAS 容量、完整高可用和持续运行单列。

平台授权L待报价；全文档库规模仍需实地盘点。

备查：公司容量与 A100 公开结果

配置 / 实现	保留会话或速度	条件
8×H200 TP8	20 份各 1M； 40 份各约 636K	缓存容量估算
8×H200 双 TP4	20 份各 1M； 40 份各约 762K	缓存容量估算
shi3z / 4×A100 PCIe	代码 50—53； MTP82—93 token/s	短输入单路
modified vLLM / 8×A100 SXM	单路 110—140 32 路总 1,040—1,379 token/s	DSpark5 公开测试记录
Tokha / 8×A800 SXM	2,842→2,926→2,971 token/s	同机两项优化，合计约 +4.5%

八 H200 按约 1.5TB 主机内存规划； A100 作为已有资源或低成本候选，具体能力单独核验。

容量估算与不同硬件的公开性能分别记录；完整推导与配置见知识库。

备查：三年成本计算输入

输入	数值
DeepSeek 低峰 输入 / 缓存读 / 输出	0.15 / 0.003 / 0.60；高峰 ×2，假设 80% 高峰
Sonnet5.5： 输入 / 1h 写 / 读 / 输出	2.00 / 4.00 / 0.10 / 10.00
三年个人任务	2,482.5 项；本地 9.05 、 DeepSeek1.66 、 Sonnet3.75 万元
三年公司任务	95,312.5 项；本地 392.54 、 DeepSeek68.34 、 Sonnet148.61 万元
技术与业务人力	2,500 元 / 技术人日； 150 元 / 分析师小时
公司容量预算	400 生成 + 8,000 新输入 token/s； 2,000h / 年，留 30%

资料分类先决定可用路线。业务人员复核时间计入净节省，技术运维人工已计入 TCO 。

费率单位：美元 / 百万token。Sonnet为适用主体和地域成立时的全球价格参照。

资料与详细方案

行业案例与历史成果

github.com

模型与金融任务评测

www.vals.ai

AI Infra Book

github.com

vLLM缓存卸载

docs.vllm.ai

LMCache分层存储

docs.lmcache.ai

DeepSeek计费规则

api-docs.deepseek.com

A100适配与性能消融

github.com

项目与完整研究

github.com

配套讲稿提供每页解释与来源；知识库保留配置、成本、许可和公开评测的详细记录。