

本地大模型 部署方案

配置选择、落地方式与业务产物



场景 1
个人与小组



场景 2
公司知识库



场景 3
公司通用 Agent

三档部署，分别交付不同的工作能力

以下按代表配置的硬件预算排序，软件与实施费用单独计量

1	个人与小组 Agent 长会话、代码与文件处理，成果留在个人工作区	约 4-38 万 四种个人 / 小组配置
2	公司知识库与问答 员工按原有限权查资料，获得答案与引用	74-141 万 四卡 6000D 与两台应用节点
3	公司共享模型与通用 Agent Agent 查询资料、调用工具，交付表格与报告	255-512 万 含知识库底座的合计硬件

预算单位：人民币万元。场景按投入递增编号。价格观察与估算日期见附录 B。

个人 Agent：模型可以共享，工作环境由各自掌握

投研、数据与 IT 同事在自己的项目中使用 Agent，处理文件并执行代码



交付什么

代码改动与测试记录
可重跑的数据脚本
可编辑表格与文稿

本机文件、命令与 NAS 访问沿用员工身份
团队共用 Skills、模板和校验方法

共享节点承担模型推理。每人独立保存会话、工具凭据和产物。模型接口与 Harness 的工具协议需要配套。依据：场景一方案。

个人与小组的四套配置

Qwen3.8-27B：FP8 权重，BF16 / FP16 KV，优先满足单人长会话

硬件配置	单人上下文	主要特点	整机预算 / 万元
DGX Spark 128GB	524K	CUDA 开发、低功耗	4-5
M5 Ultra 256GB	524K	桌面环境、大内存	9.05
单 6000D 84GB	262K；524K 紧配	较低预算的 GPU 节点	13.2-24.5
双 6000D，TP2	524K	单人速度优先	20.9-38.0

Mac 为 9 月 21 日官网配置价，其余为 D 整机预算；6000D 含配套服务器。524K 采用 YaRN×2。Mac 以 MLX MXFP8 部署。Spark 预算据 9 月 24 日美元标价与交付准备。

四套配置的单人生成速度

接近满窗口的 decode 估算，单位：token/s；单活跃请求，MTP 关闭


配置	131K	262K	524K	262K：双卡约 23 524K 约 17 token/s 20+ 作为提速验收目标 容量与速度分别看 M5 Ultra 可驻留 三人各 524K 会话
DGX Spark	4.1	3.4	2.5	
M5 Ultra 256GB	17.5	14.5	10.8	
单 6000D	20.3	16.8	12.5*	
双 6000D TP2	26.7	22.6	17.3	

* 单 6000D 的 524K 需 95% 显存预算，缓存余量约 1.7GB；其余按 90%。基准有效带宽 60%，双卡另计 TP 效率与通信。原生 MTP 进入同负载实测。

公司知识库：把 NAS 资料变成按权限可查询的答案

投研、风控合规和运营同事，按原有权限查阅制度与部门资料

员工登录与问题



能获得：带来源的制度问答、部门资料查询和历史文件查找

Word、PDF、PPT 与 Excel 统一入库，内容与权限变更同步到检索服务

RAG：先检索获授权的资料片段，再由模型组织答案。NAS 适配包括权限映射、撤权同步和引用文件访问。依据：场景二方案。

企业平台与自建方案，区别在交付和维护分工

Onyx Enterprise

适合希望采购完整平台与交付支持的团队

现成知识管理、员工入口与权限能力
供应商承担约定范围的平台交付
采购范围包含 NAS 连接与权限验收

硬件 + 首次实施：84.5-158 万 + L

Milvus + 自建 RAG

适合已有平台研发与维护能力的团队

Milvus 承担检索，Open WebUI 提供入口
团队开发 NAS 权限、解析与 RAG 服务
Embedding / reranker 采用本地开放模型

硬件 + 首次实施：91.5-168.5 万

单位：人民币万元。同为四卡 6000D 常规配置。L 为 Onyx 企业授权 / 支持报价变量，未填入假设成交价。依据：场景二成本数据。

问答服务按并发与等待时间选择硬件

20 个请求同到达，每路 8K 输入与 600 输出，三种配置使用同一 Qwen3.8-27B FP8 模型

成本对照配置

4×6000D

74-141 万元

3 张回答卡，1 张辅助卡
首 token 约 37.4 秒
600-token 回答约 65.3 秒

增加问答并行量

8×6000D

121-226 万元

7 张回答卡，1 张辅助卡
首 token 约 16.5 秒
600-token 回答约 41.8 秒

缩短模型响应

4×H200 NVL

181-371 万元

3 张回答卡，1 张辅助卡
首 token 约 7.5 秒
600-token 回答约 16.4 秒

硬件金额含 GPU 整机与两台应用／检索 CPU 节点。时间为工程估算，包含 0.8 秒前置检索链路，取该批最慢请求。

通用 Agent：从资料查询扩展到完整工作产物

示例：交给 Agent 两期财报和 Excel，获得比较表、图表与说明



确定性脚本检查数字，Agent 整合成果

Skills 保存业务方法与模板，MCP 连接受权限控制的工具。授权检索复用场景二，文件、会话和产物按员工／项目隔离。

通用 Agent 按每任务 262K 配置

MiMo-V2.6 官方制品，20 个长任务同时驻留并推理。金额为新增硬件

均衡通用任务

MiMo Flash 309B
4×H200，TP4

181-371 万元

每路生成约 34 token/s
20 任务时每任务上限
566,016 tokens

增加同时推理量

MiMo Flash 309B
8×H200，两组 TP4

302-378 万元

每路生成约 52 token/s
20 任务时每任务上限
1,048,576 tokens

运行更大模型

MiMo Pro 1.02T
8×H200，TP8

302-378 万元

每路生成约 28 token/s
20 任务时每任务上限
322,816 tokens

工程估算：每任务 262K 包含 8K 输出，续跑新增 1K 输入。上下文上限按 20 任务分配，要求滑窗 KV 回收。新增硬件已含 CPU 执行节点。

工具执行的位置，决定管理方式与 CPU 投入

集中执行

服务器维护独立的员工 / 项目环境
统一任务队列、依赖和产物管理
适合批量文件处理与较长任务

2 台 CPU 执行节点：12-26 万元
基准配置 8 个重工具执行槽位

员工电脑执行

员工本机运行 Hermes 和工具
共享同一模型服务，使用本机 NAS 权限
适合与个人当前文件紧密相关的工作

1 台网关 / 工具节点：6-13 万元
复用现有员工电脑

模型推理和工具执行分别扩容，监测请求排队与工具槽位占用

CPU 金额已经包含在相应场景三增量预算中，不重复加总。每个员工的工具身份与会话分别管理。依据：场景三部署与成本数据。

配置选择与首批交付

每套方案先固定使用方式和代表任务，再校准硬件与响应目标

个人与小组

双 6000D 优先验证 262K 下单人 20+
524K 检查 MTP 效果、峰值显存与冷 / 热续跑

公司知识库

选 Onyx 交付或 Milvus 自建分工
首批交付：NAS 权限同步、资料入库、答案与引用

公司通用 Agent

先接财报 / Excel 比较和材料汇总
复用知识库，用同一任务检查产物、等待和人工复核量

三套方案可按投入逐步推进。第一轮试用的目标是形成可交付成果，并取得对应设备和任务的性能数据。

计算口径与验收指标

个人／小组 Agent

Qwen3.8-27B，FP8 权重、BF16 KV
单人 131K / 262K / 524K，含 8K 输出
缓存池：单卡 38.6 / 双卡 108.2GB
Mac 164.6 / Spark 56.6GB

公司服务层

知识库：Qwen27 FP8，8K 输入 / 600 输出
通用 Agent：MiMo，每任务 262K
20 任务同时驻留与推理
续跑命中前缀，新增 1K 输入

性能采用硬件规格、模型结构与显式效率假设，尚未做目标设备实测。验收同时记录 prefill、decode、每路速度、首 token、产物质量和实际缓存占用。

带宽利用率基准 60%，个人双 6000D 另设 75% 并行效率与 PCIe 通信。KV 保持完整精度，另留 8 份状态检查点。MTP 关闭，冷／热 prefill 分别计算。

硬件预算与计价依据

配置	硬件预算	计价范围
DGX Spark 128GB / 4TB	4-5	D: 美元标价折算及中国交付准备
M5 Ultra 256GB / 2TB	9.05	官网含税价，未加 AppleCare
单 6000D / 双 6000D TP2	13.2-24.5 / 20.9-38.0	D: 配套服务器、税费及交付支持
知识库, 4×6000D	74-141	含两台 CPU 节点；实施与授权另计
通用 Agent, 4×H200 新增	181-371	含执行节点；与知识库合计 255-512

D 为分析预算。Spark 依据 9 月 24 日 USD4,699 及 7.00 情景汇率，其余价格依据见各方案。Onyx 授权以 L 计，软件实施单列；完整 BOM 与人工预算见三份方案 PDF。

通用 Agent：每个并发任务能分到多少 context

下表按同时驻留的任务数分配，单位为每任务总 tokens，包含输出

模型与服务器	5 任务	20 任务	30 任务	50 任务
4×H200 / Flash	1,048,576	566,016	376,832	225,792*
8×H200 / 双 Flash	1,048,576	1,048,576	755,200	452,608
8×H200 / Pro	1,048,576	322,816	214,784*	128,512*
8×MI325X / 双 Flash	1,048,576	1,048,576	1,048,576	1,048,576

* 低于 262K 最低档，需要减少同时驻留任务或扩容。按 BF16 KV 和滑窗回收计算，取模型窗口与内存上限。副本内最多 32 路活动请求，工具槽位另计。

来源与进一步阅读

方案与计算数据

场景一：四种个人／小组配置
场景二：Onyx 与 Milvus 企业 RAG
场景三：共享模型与 Hermes Agent

三份方案及其计算输入保存在知识库
性能数据更新至 2026.09.24
价格分别标注观察日期与估算口径

主要官方资料

Apple 规格 DGX Spark
Qwen FP8 与 MTP 部署
Onyx 文档 Milvus 文档
Hermes Agent vLLM 文档

Qwen27 模型与长 context 配置
MiMo Flash 服务配置

原文、版本与计算依据对应知识库 TECH-068 至 TECH-075 及硬件价格台账。演示稿源码和所用数值的逐项出处与 PDF 一并保存。