第七周汇报

本地长上下文 Agent 部署与推理优化

个人与公司方案、A100 实现、AI Infra Book

Spark
个人部署

DeepSeek
公司服务

A100 与
推理优化

2026 年 10 月 15 日

本次汇报的四个主题

01

Spark 个人方案

每人能用多大的上下文，生成多快，投入多少

02

DeepSeek 公司方案

20 个长会话的缓存容量、并发目标和服务器预算

03

A100 项目

实现特点与 modified vLLM 对照

04

AI Infra Book

计算、缓存与任务成本

基础上下文：131K ／ 262K。长上下文：512K ／ 1M。总量均包含输入与输出。

Spark 运行模型，员工电脑执行工具

Qwen3.8-27B 提供模型判断，OpenCode 管理文件、工具调用与产物



模型可共享，每个人的文件目录、账号和会话保持独立

交付产物

代码与测试
Excel 与图表
有出处的说明

性能数据采用 FP8 权重、FP8 KV Cache 和 MTP3。BF16 KV 容量见附录 B，完整配置与说明见汇报讲稿。

Spark 单人生成速度与首次等待

单请求接近用满上下文，预留 8K 输出。下表为 FP8 KV + MTP3 估算

总上下文	生成速度／ token/s	首次 prefill ／分钟
131K	19.7	3.1
262K	17.7	8.6
512K	14.7	25.8
1M*	11.2	78.9

单人目标

20+

token/s

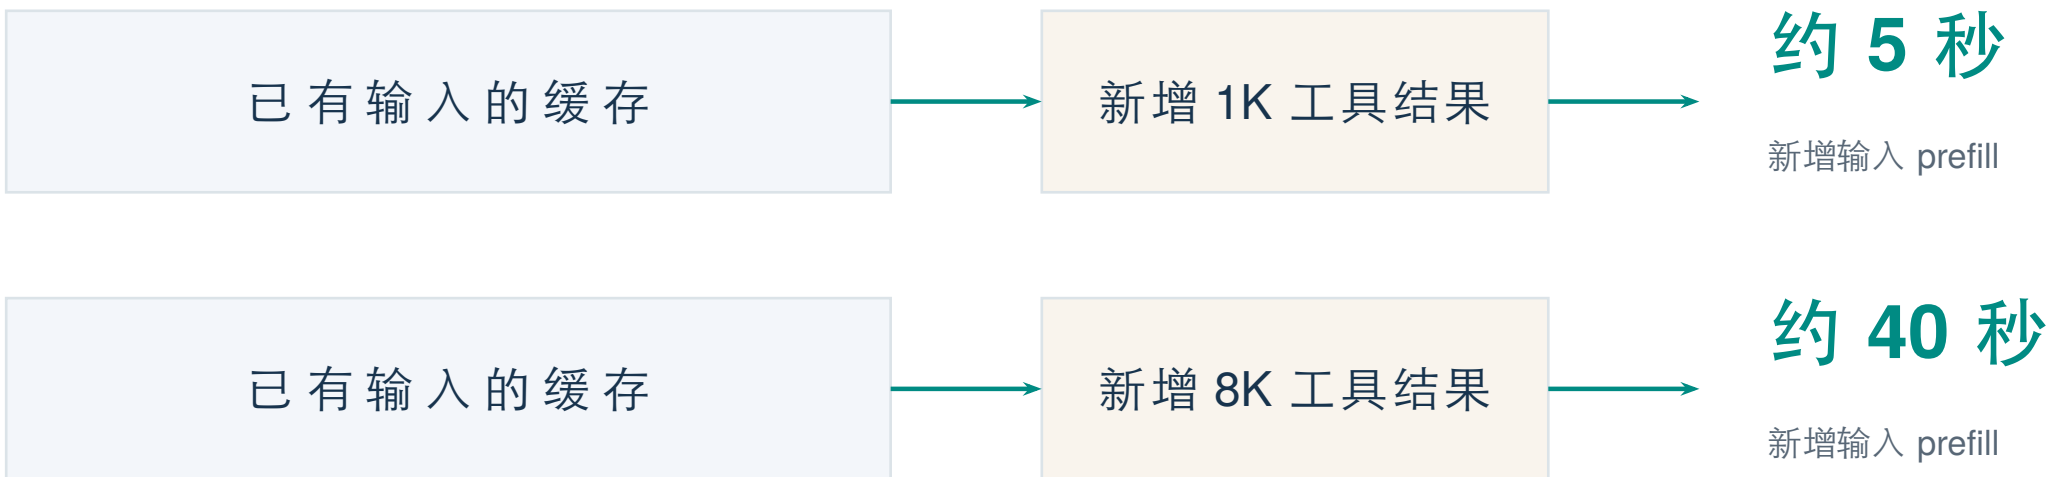
512K 约 15
低于当前目标

*1M 速度为外推。依据：单台 Spark 外部实测及四档估算；实测 100K 约 20.1、500K 约 14.8 token/s，详见附录 A。

缓存命中后，只对新增输入做 prefill

两种请求总上下文均接近 512K，预留 8K 输出，本轮工具结果已包含在总量中

以下假设原输入的 KV Cache 和线性注意力状态已在 GPU 上，可直接复用

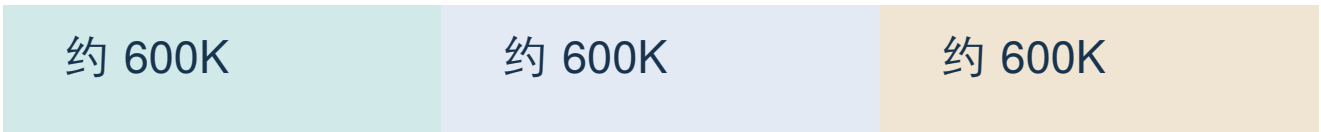


5 秒与 40 秒是新增 prefill 的计算估算。首 token 等待还包括排队和第一步 decode。缓存命中省去重复 prefill，decode 仍需读取 KV。

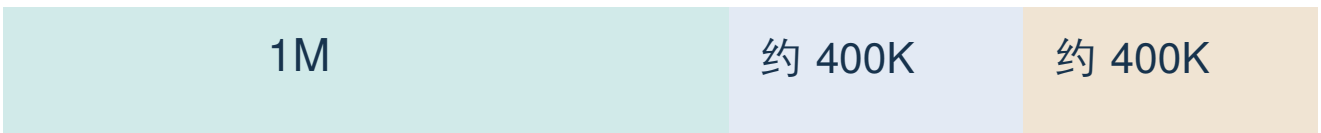
三人共享 1.81M token 的 KV Cache

FP8 KV Cache 总池约 1.81M token，按请求分配

三人均分



一人使用 1M，另外两人共用约 810K



人民币预算

硬件：5.8-6.2 万

个人实施：1-2 万

6.8-8.2 万

个人硬件与实施合计

留 10% 缓存余量时，三人可各配置 512K。三人共享的硬件与实施合计 7.8-9.9 万元。价格为 10 月 12 日估算，构成见附录 D。

公司知识库提供按权限检索的资料

员工问答和通用 Agent 共用一套 NAS 检索接口



Onyx Enterprise

平台、NAS 适配与交付支持

Milvus + 自建 RAG

团队维护权限同步、索引与管理接口

Word、PDF、PPT、Excel 共用入库流程。内容进入重排和模型前完成权限过滤，原文入口复核权限。详见公司知识库方案。

公司 Agent 共享模型，各自执行任务

目标：20 个同时活跃的任务，每个最多 1M 上下文



工具在员工电脑或 CPU 服务器执行
MCP 复用公司知识库和业务接口

Engram 表按模型实例计。KV Cache 按所有保留会话计，包括正在等待工具的会话。用户身份随检索请求传递。

20 个会话分别能分到多少上下文

按公开启动池及图捕获后预算估算，再预留 10% 缓存容量

配置	每会话上下文
8×H100，TP8	约 242K
4×H200，TP4	约 762K
8×H200	1M

同机两种部署

TP8：一个实例
一组队列，20 人

Engram 主存约 203GB

双 TP4：两组各 10 人

两份 Engram 约 406GB

1M 总量含 8K 输出预留。H100 的约 242K 低于 20 人各 262K 所需容量。该页描述缓存容量，20 路满 1M 的速度另需对应负载测量。

等待工具的请求也占用 KV Cache

20 个请求在 decode

使用 GPU 计算与 KV Cache

20 个请求在等工具

暂不生成，继续保留 KV Cache

缓存按 40 份上下文计算

闲置会话可移至 CPU 内存
继续任务时，再复制回 GPU

生成速度目标

20 路 × 20 token/s
= 400 token/s 系统输出

若每路 10 token/s，系统目标为 200。当前 TP4 实现恢复一个 1M 会话的四份全局 KV 约需传输 7.3GB，另计复制等待。

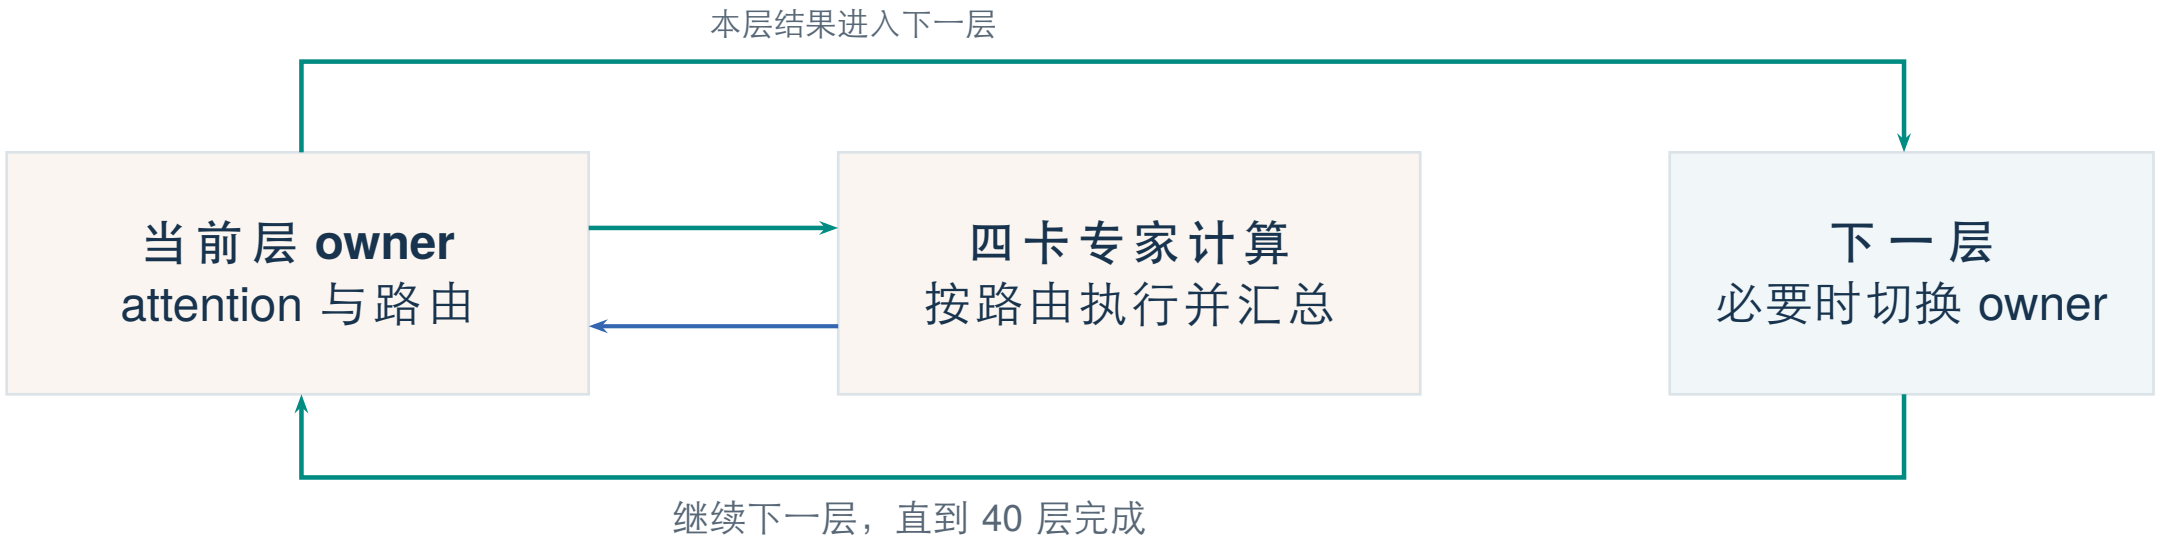
服务器预算与公司推理引擎

完整 GPU 服务器	交付预算估算	主机内存
8×A100 80GB SXM，翻新	91-102	1TB
8×H100 80GB SXM	285-298	1.5TB
4×H200 141GB NVL	161-283	1TB
8×H200 141GB SXM	291-304	1.5TB

10 月 12 日价格与估算，USD/CNY=7.00。集中工具执行另加 12-26 万元。公司采用 A100 时选择固定版本 modified vLLM，详见 A100 部分。

A100 项目：新模型在四卡机器上的移植

稠密部分按层指定 owner GPU，路由专家分散到四张卡上



CPU 内存放 Engram，GPU 保存其余权重和会话缓存

项目主配置：4×A100 80GB PCIe，两组 NVLink 卡对，组间 PCIe。源码固定 580568e。箭头表示一层内协作与层间推进。

模型能力、通用优化与项目实现

来源	具体内容
DeepSeek 模型	原生 FP4 ／ FP8 权重、CED、共享 KV、DSpark 决定计算路径与原生存储格式
成熟引擎	并行、CUDA Graph、算子融合、前缀缓存 提供已有的执行与服务方法
项目实现	A100 算子适配、按 NVLink 卡对通信 保存与载入会话缓存

学习重点：硬件适配、通信安排和缓存管理。来源：DeepSeek 模型卡、vLLM 文档、shi3z 源码及 modified vLLM 测试记录。

公开测速保留各自的硬件与负载

短输入结果，单位 token/s。四卡 PCIe 与八卡 SXM 分别列示

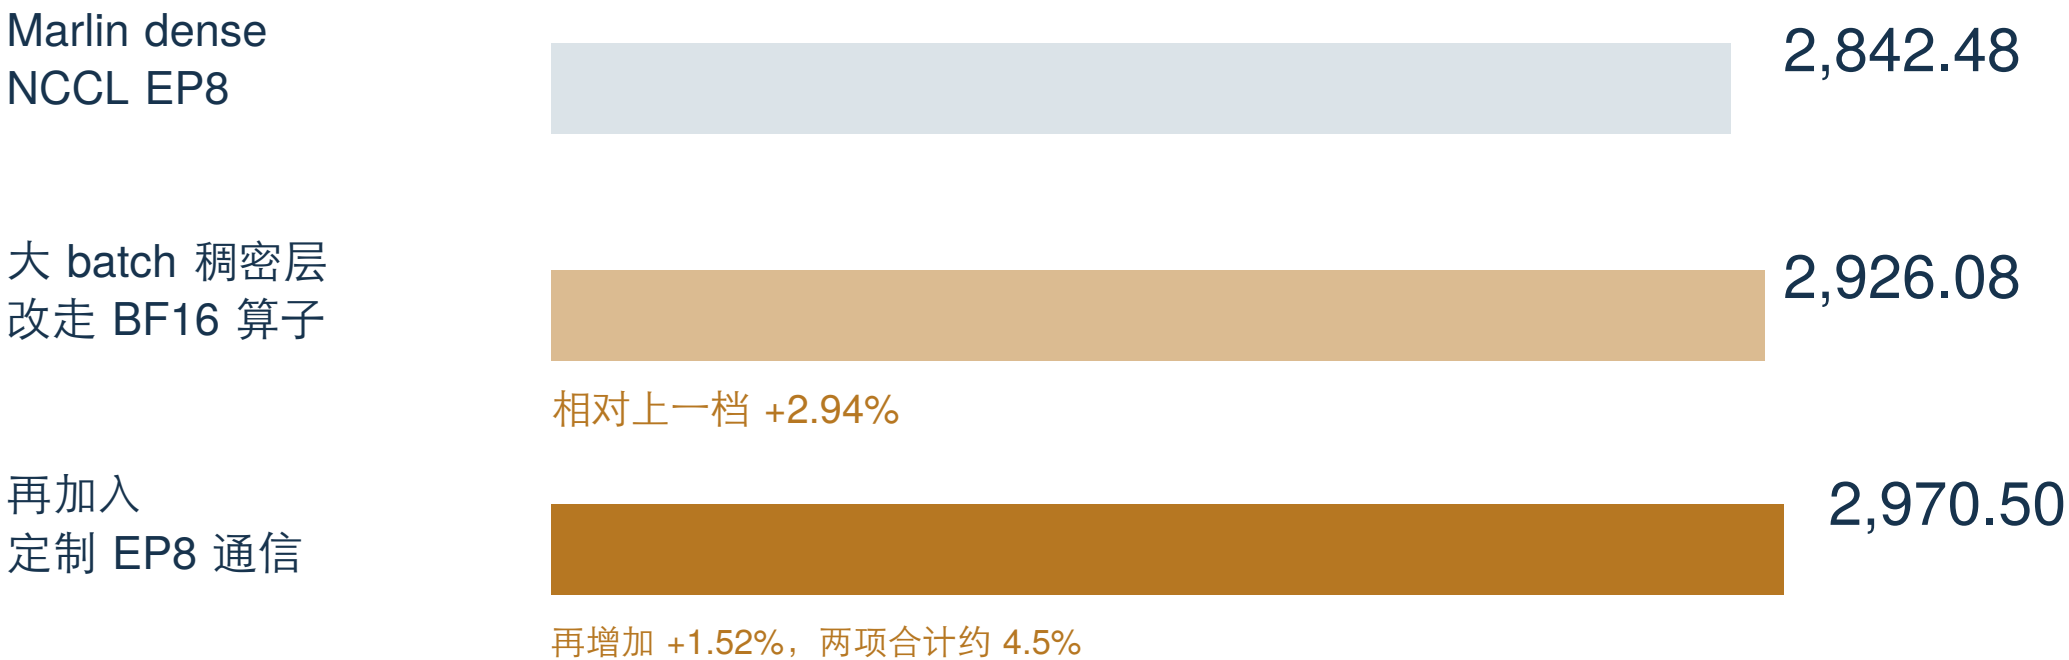
实现与硬件	单路结果	多路结果
shi3z 4×A100 PCIe	代码 HTTP：50-53 MTP 实验：82-93	64 路端到端：167.5 引擎峰值：475.6
modified vLLM 8×A100 SXM	DSpark5 decode 110-140	32 并发总输出 1,040-1,379

公司 A100 采用 modified vLLM，复用调度、缓存、接口与监控

第一行来自作者不同实验。第二行为 keplerzip 历史 TP8、短输入 1,024 输出的操作者回传结果。缺少两套引擎的同机同负载直接对照。

同机消融量出每项改动的额外收益

八卡 A800，128 并发，每档两次；总输出 token/s。基线含 DSpark、Marlin 和 CUDA Graph



条形从零起算，长度与输出吞吐成比例。输入 78-90、输出 1,024 tokens。来源：Tokha233 公开消融与测试协议。

四卡显存从官方 510GB 原生制品起算

官方 checkpoint 约 510.29GB，原生采用 FP4 专家与 FP8 稠密权重

Engram 202.76GB	其余权重 307.53GB
放在主机内存	约 286.41GiB，分配到 GPU

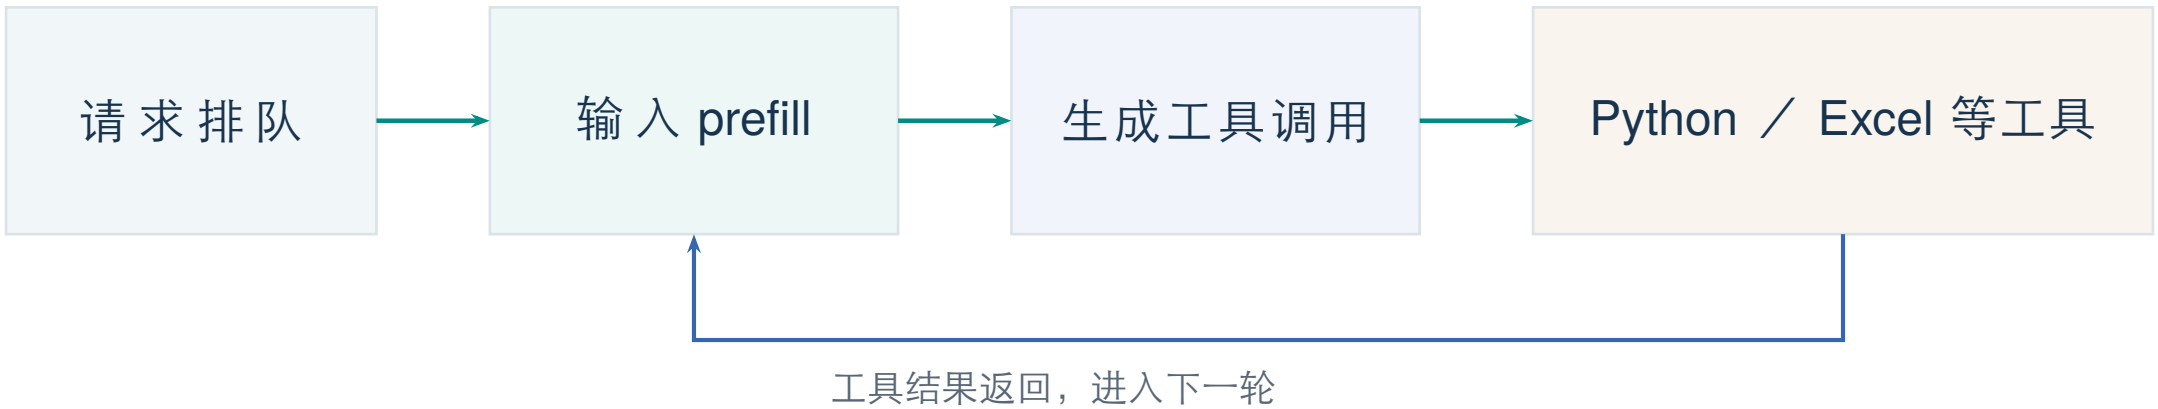
四卡平均 71.60GiB

每卡还需 KV Cache、草稿与工作区
具体分片决定最紧张的一张卡

原生权重与 Engram 卸载是模型和框架已有路径。项目进一步处理算子、分配和临时张量。依据：官方 tensor 索引与机制复算。

一次 Agent 任务的完整耗时

以财报任务为例，用户等待的是输入处理、生成和工具执行的总时间



读取 100GB，若有效带宽为 1TB/s，仅传输约需 0.1 秒

每阶段分别估算计算量／有效算力、字节数／有效带宽，再计入前后依赖和排队。来源：AI Infra Book 第 8、9、11 章。

合批分摊权重读取，KV 按请求分别读取

稠密模型的简化读取量，按每个输出 token 计

权重读取量 ÷ batch 内请求数 + 该请求的 KV 读取量

上下文较短
权重读取占比大，合批收益明显

上下文较长
每个请求要读取更多 KV

Qwen 从 512K 增至 1M：KV 约 1.9 倍，全注意力冷 prefill 计算约 3.7 倍

1.9 倍指 KV 容量，3.7 倍指全注意力部分的计算量。缓存命中可省重复 prefill，新增输入仍需读取已有 KV。来源：Book 算例。

CPU 不忙时，任务环境仍可能占用大量内存

每 10 秒到达 1 项任务，每项 3 轮。每轮模型 60 秒、工具 10 秒，工具实际消耗 4 核秒

资源	计算	平均需求
尚未完成的任务	210 秒 ÷ 10 秒	21 项
处于模型阶段的任务	180 秒 ÷ 10 秒	18 项
工具 CPU	12 核秒 ÷ 10 秒	1.2 核
工具环境内存	21 项 × 2GiB	42GiB

教学假设：稳定到达、忽略排队，每个环境占 2GiB 并保留至任务结束。模型 KV、工具 CPU 与环境内存分别预算。

配置选择与使用方式

个人 **Spark**	Qwen27，工具在员工电脑执行 512K 估算约 15 token/s，共享 KV 约 1.81M tokens
公司 **DeepSeek**	八卡 H200 为主要候选，比较 TP8 与双 TP4 缓存可容纳 20 个 1M 会话，按活跃及等待任务计容量
公司 **A100**	采用固定版本 modified vLLM 学习 shi3z 的实现思路，按同机测试选择补丁

个人 20+ token/s 目标仍高于 512K 的当前估算。公司 20 路满 1M 速度需匹配负载验证。最终经济性按合格任务的时间与成本比较。

Spark 单请求实测与四档估算的关系

单 GB10，FP8 权重 + FP8 KV，MTP3，随机 token 输入，前缀缓存关闭

实际输入 token	输出 token	平均 TTFT ／秒	decode ／ token/s
1,024	2,048	0.6	20.53
50,000	2,048	63.1	21.01
100,000	2,048	144.8	20.11
300,000	2,048	658.9	17.23
500,000	2,048	1,470.1	14.82

另有 999,936 输入 + 64 输出的 1M 容量测试：TTFT4,815.8 秒，短段 decode9.83。四档估算预留 8K 输出，与本表实际长度分别记录。

缓存池、运行缓冲与上下文容量

公开配置	已分配 KV ／卡	实例 token 池	严格预算／卡
H100 TP8	12.36GiB	6.435M	10.34GiB
H200 TP4	35.16GiB	18.327M	32.49GiB
H200 TP8	62.86GiB	29.498M	60.20GiB

Spark FP8 池：1,806,907 tokens。BF16 容量约减半，可容纳单人 512K 或三人各 262K

公司主表对 graph 后建议预算线性调整，再留 10%tokens。Spark BF16 为同池容量近似。预留空闲 tokens 不会释放已分配的物理内存。

公司服务的公开多轮回放参照

平均输入 140K-157K，前缀命中约 95%，预设 DSpark 平均接受长度 3.51

配置与回放会话数	总输出／ token/s	TTFT 均值／ p95 秒
H100 TP8，20	718.48	2.05 ／ 6.98
H200 TP4，16	614.76	0.83 ／ 3.03
H200 TP4，32	922.61	1.47 ／ 5.12
H200 TP8，16	661.15	0.65 ／ 2.14
H200 TP8，32	1,052.18	0.85 ／ 2.63

端到端总输出含输入处理与调度。回放包含生成与等待工具两个阶段；该表用于 140K-157K 输入下的性能参照。来源：vLLM AgentX 记录。

预算包含什么，哪些费用单独计算

Spark 预算

美国页面价：6,950 美元
预算汇率：1 美元 = 7.00 元
税费、运输与支持准备另加
国内交付估算：5.8-6.2 万元

个人实施：4-8 人天 × 2,500 元
三人实施：8-15 人天 × 2,500 元

GPU 服务器预算

完整主机挂牌或组件 BOM
加 13% 税费准备、10% 价格预留
交付及本地支持单列
CPU、RAM、电源按已含配置计一次

工具 CPU 节点另加 12-26 万元
机房改造、软件授权与长期运维另计

价格观察／估算日期为 2026 年 10 月 12 日。人民币范围为预算，不是境内成交报价。准确 SKU、供应商交付路线与许可文件随采购核对。

主要来源与继续阅读

模型与推理引擎

DeepSeek-V4.1-Flash 模型与权重

vLLM 源码与 Engram 实现

shi3z A100 定制 runtime

modified vLLM 的 A800 测试与消融

AI Infra Book

李博杰：深入理解 AI Infra

第 8 章：推理优化

第 9 章：分布式推理

第 11 章：资源调度与运行环境

完整解释见本次汇报讲稿与场景方案，知识库保留原文、版本和计算输入

资料截至 2026 年 10 月 14 日。Spark 数据来自外部设备测试；AI Infra Book 与 A100 源码采用本次研究归档版本。