

场景一：个人 / 小组的Qwen3.8-27B与Coding Agent部署

更新：2026年9月24日。 本方案比较四套硬件，统一 **Qwen3.8-27B**、**FP8权重**、**BF16 / FP16 KV**，优先保证单人20+ token/s。262K为原生窗口，524K采用YaRN×2；三人容量只用于说明共享空间。

双6000D是速度优先的主候选，**M5 Ultra**是容量充足的桌面方案，单6000D是较低预算的GPU节点，**Spark**侧重低功耗**CUDA**开发。未启用投机解码的分析基线中，双6000D在262K约23 token/s，524K约17 token/s；524K / 20+作为其优化和验收目标。

使用方式与交付物

员工在自己的项目目录运行OpenCode / pi等Coding Agent，连接本机或个人 / 团队专用模型节点。模型可以远程共享，代码、命令、NAS权限和产物仍由每位员工的运行环境管理。团队共同维护Skills、模板和校验脚本。

典型任务包括修改代码并执行测试、编写数据处理脚本、比较多份材料、整理表格和生成报告。交付物是可重跑脚本、代码改动、测试记录，以及可编辑表格或文稿。共享服务的会话和日志按员工隔离，工具使用各自的文件权限。

个人环境首次部署按4–8人天、团队共享按8–15人天准备，沿用2,500元 / 人天的D级人工假设，分别为1–2万元、2–3.75万元；与下方硬件预算分开。范围包括固定模型和引擎版本、入口认证、Skills与NAS工具配置、长窗口任务和产物质量验证。

1. 配置与人民币预算

配置	物理显存 / 统一内存	标称内存带宽	软件路线	硬件预算
单6000D	84GB独立显存	1,398GB/s	Linux + vLLM / SGLang, TP1	13.2–24.5万元，D整机估算
双6000D	2×84GB独立显存	每卡1,398GB/s	Linux + vLLM / SGLang, 一个模型TP2	20.9–38.0万元，D整机估算
M5 Ultra 256GB	256GB统一内存	1,200GB/s	macOS + MLX-LM, MXFP8	90,499元，9月21日官网配置价
DGX Spark	128GB统一内存	273GB/s	DGX OS + ARM64 / SM121引擎	4–5万元，D中国交付预算

6000D指84GB **Blackwell Server Edition**被动散热卡；整机预算包含配套服务器、另配128GB主存 / 4TB NVMe。双卡采用真正的tensor parallel，需支持PCIe P2P的插槽拓扑；带宽计算另扣并行效率和通信开销。主机RAM不与显存相加。[HPE规格与采购记录](#)

Mac沿用36核CPU / 80核GPU、256GB / 2TB配置；系统和工具预留32GB。Spark本轮为NVIDIA品牌 128GB / 4TB整机，系统和工具预留24GB。[Apple规格](#) · [Spark硬件说明](#)

价格怎么得到

6000D：D级逐项预算，整机报价尚未取得。 GPU单卡沿用台账5.0–8.5万元税前分析值，以历史挂牌为锚点并留渠道差异；其余为本轮小型集成服务器准备。不将四卡整机总价按卡数等分。

税前组件 / 万元	单6000D	双6000D
GPU	5.0–8.5	10.0–17.0
16–32核CPU	0.8–1.6	0.8–1.6
128GB RDIMM主存	1.6–3.4	1.6–3.4
2×2TB NVMe	0.3–0.6	0.3–0.6
10GbE网卡	0.15–0.35	0.15–0.35
机箱、主板、riser	1.8–3.2	2.5–4.5
电源、强制风冷、供电线材	0.8–1.6	1.2–2.4
税前硬件小计	10.45–19.25	16.55–29.85
交付及三年硬件支持准备，含税	0.4–0.8	0.6–1.2

整机现金预算 = 硬件 × (1 + 13%硬件税费准备 + 10%价格预留) + 含税交付 / 支持准备，分别为132,535–244,775元和209,565–379,155元。供方按600W被动卡要求匹配散热、电源、CPU通道和插槽；表内为询价目标，品牌OEM配置单独报价。采用既有机柜和网络，未计新增机房、软件实施及电费。主机组件是工程估计，GPU来源见既有台账，这些数值不是HPE原厂报价。

Spark：9月24日NVIDIA美国商城标价 **USD4,699**、显示缺货。按1美元 = 7元的情景汇率折算32,893元，加13%税费准备为37,169元；中国交付暂按 **4–5万元D预算**，用于渠道、运输和服务差异。台账中的GX10 39,999元 / PGX 48,999元为其他厂商品牌，可作同GB10平台参照。[NVIDIA商城](#)

Mac：90,499元沿用9月21日含税、标准配送的官网配置观察，未加AppleCare；本轮重核技术规格。[Apple配置入口](#)

2. FP8在两个平台上的具体含义

- **NVIDIA：**官方Qwen3.8-27B-FP8，E4M3、分块缩放；归档tensor合计约30.864GB，常驻预算31GB。KV显式保持BF16，线性注意力递归状态保留FP32。

- **Mac**: MLX已支持 **MXFP8**，每32个E4M3数值共享一个E8M0尺度；MLX-LM主线提供 `--q-mode mxfp8`。从BF16原模型转换、保持KV为BF16 / FP16。本轮同样预留31GB权重，属于工程预算，尚未生成该制品。[MLX格式说明 · 固定版本转换源码](#)

此前社区MLX 8-bit的affine整数格式与MXFP8分开记录；本表Mac也从原30GB预算改为31GB。两平台均是8-bit浮点权重路线，具体量化尺度与产物不同。

3. 长context能放多少

Qwen3.8-27B的16层full attention、4个KV heads、256维、每值2字节，得到 **65,536 bytes/token**。每会话固定状态153.94MB；预留8份额外状态检查点，缓存和状态再加15%准备。

每人总context	纯BF16 KV	加状态 / 检查点 / 缓存准备
131,072	8.59GB	11.47GB
262,144	17.18GB	21.35GB
524,288	34.36GB	41.11GB

GPU / UMA可用推理预算取90%，每设备运行时预留6GB，再扣权重。GB按十进制保守计算；正式部署用设备报告的可用字节复算。

配置	KV与状态缓存池	单会话：仅内存约束 token上限	三会话均分：每人内存上限	三人各262K / 各524K
单6000D	38.60GB	491,008	149,504	空间不足 / 空间不足
双6000D TP2	108.20GB	1,414,400	457,216	可容纳 / 空间不足
M5 Ultra 256GB	164.60GB	2,162,688	706,816	可容纳 / 可容纳
DGX Spark	56.60GB	729,856	229,120	空间不足 / 空间不足

上述内存上限用于比较容量，实际每请求仍按262K原生 / 524K扩展配置；三人驻留容量与同时生成速度分开评估。

单6000D的524K是紧边界。90%预算下缺2.51GB；提高到95%后缓存池42.80GB，留1.69GB余量。这一分支需检查实际长prefill峰值；主表继续保留90%预算。

4. 单人生成速度

单位为**每请求decode token/s**，单活跃请求时也等于当时系统的输出吞吐。输入token不计入decode，MTP / 外部draft关闭。输出预留8,192tokens，读取长度按该输出段平均位置计算。

数值为同口径分析估算。基准有效带宽60%，敏感性45%–75%，单步固定开销4 / 2 / 1ms；双卡另设75%并行效率及PCIe通信。括号来自这些输入情景，不是实测区间或统计置信区间。

配置	131K	262K	524K
单6000D	20.3 (14.9–25.7)	16.8 (12.4–21.3)	90%预算不足；95%分支约12.5
双6000D TP2	26.7 (20.0–33.2)	22.6 (16.9–28.1)	17.3 (12.9–21.5)
M5 Ultra 256GB	17.5 (12.9–22.2)	14.5 (10.7–18.3)	10.8 (8.0–13.6)
DGX Spark	4.1 (3.1–5.1)	3.4 (2.5–4.2)	2.5 (1.9–3.1)

上一轮双6000D约27 / 23 token/s使用8-bit KV；本轮恢复完整精度KV，改为约23 / 17 token/s。

为什么Spark低、双卡也没有翻倍

262K / 524K附近每步需读取约 **48.3 / 65.4GB** 权重、KV和活跃状态，单人decode主要看有效内存带宽。

- **Spark**：273GB/s全部用于上述读取时，普通逐token解码的内存侧上界约5.7 / 4.2 token/s。它适合放模型、调CUDA工具链，27B dense长会话速度是弱项。
- **M5 Ultra**：带宽约为Spark的4.4倍，256GB又可容纳更多长会话；到524K仍需读取约65GB / 步，大内存解决容量，生成速度另外受带宽影响。
- **双6000D**：TP2分摊权重与KV读取，每层交换中间结果。本轮每层2次collective、每次30μs、有效链路24GB/s，单步通信约3.89ms，再计并行效率折扣。

MTP作为下一步提速测试

vLLM官方Qwen recipe提供原生MTP；在FP8权重 + BF16 KV下试验时，同时记录接受率、速度和显存峰值。[官方recipe](#)

本轮找到Spark测试作者发布的短输入测量：FP8单流从7.9提高到17.1 token/s（MTP）；负载为128输入 + 128输出，KV为FP8。该结果说明MTP值得试，本项目再按262K / 524K与BF16 KV测量。[作者原帖](#)

5. 首次读入和Agent续跑分开看

首次载入长历史要prefill；同一Agent会话续跑可通过前缀缓存复用历史。以下为 **262K窗口**的计算情景：输入253,952、输出预留8,192；冷prefill处理全部输入，热续跑命中252,928个token，只增加1,024。

配置	冷prefill输入 token/s	冷prefill + 第一步计算用时	热续跑新输入 token/s	热续跑 + 第一步计算用时
单6000D	893	285秒	618	1.7秒
双6000D TP2	1,245	204秒	880	1.2秒
M5 Ultra 256GB	286	889秒	198	5.2秒
DGX Spark	214	1,186秒	148	7.2秒

有效算力是沿用原研究的工程输入：6000D每卡100TFLOP/s，双卡再乘2×75%；Mac32TFLOP/s，Spark24TFLOP/s。表内是prefill计算预算，实际TTFT还包括队列、CPU调度和服务开销；模型已驻留，工具执行另算。缓存命中假设KV和递归状态都可复用，正式验收测冷 / 热两条路径。

6. 四种选择带来什么

1. **单6000D**：一个人的CUDA模型节点，262K容量宽松；速度基准约17，高效率情景约21，结合原生MTP验证20+目标。524K单列紧显存配置。
2. **双6000D**：优先保证一位活跃用户的长会话速度。262K基准跨过20；524K基准约17，优化有明确目标。三人可轮流调用，也能同时驻留各262K。
3. **M5 Ultra 256GB**：完整桌面环境，三人各524K有容量，单人基线约15 / 11 token/s；适合重视本地环境、静音和大内存的使用者。
4. **DGX Spark**：预算最低的完整CUDA桌面节点，单人524K可驻留；适合部署开发、工具链测试和可以等待的任务。

7. 公式与记录

每步耗时 = max（读取流量 / 有效带宽，计算量 / 有效算力）+ 固定执行开销 + TP通信。读取流量 = 31GB 权重 + 平均位置KV + 两次活跃状态 + 0.05GB临时数据；检查点计容量，不在每步全部重读。

Prefill计算量为 $F(N) = 2PN \times 1.15 + 2 \times \text{full_attention_layers} \times \text{query_heads} \times \text{head_dim} \times N^2$ ；热续跑计算 $F(N) - F(K)$ ，双卡另计通信。数值对应固定请求长度与明示效率假设，后续由设备测量校准。

- 36组主性能情景、3组单卡95%分支、8组容量与价格BOM
- 复算入口
- 本轮一手资料与源码版本

文档整理：2026年9月24日。金额、精度与性能口径按正文；来源链接及完整计算数据随项目知识库保存。