

场景二：带NAS权限的公司知识库与RAG问答方案

日期：2026年9月23日 | 状态：方案设计与预算级性能测算。

本文件为场景二的完整方案，供第四周报告选用。固定比较两条路线：**A：Onyx Enterprise私有化；B：Milvus + 自建权限 / RAG服务 + Open WebUI**。两者主用自托管Qwen3.8-27B FP8回答模型，原文件和权限继续以公司NAS为准。通用Agent属于后续场景三。

主要模型：Qwen3.8-27B-FP8。Onyx Enterprise与Milvus自建方案共用相同模型硬件。以四卡6000D、三张回答卡为例，20路8K输入 / 600输出的工程估算为：每路约21.5–22.0token/s，末路首token约37.4秒，整批约65.3秒完成。三张回答卡缓存池合计115.8GB，该负载约需16.79GB。

下文35B-A3B保留为历史效率对照，主方案与汇报均采用27B FP8。模型权重至少8-bit，KV为BF16 / FP16。性能未实测校准，硬件与人工价格沿用原记录。

1. 场景边界与比较口径

项目	已知条件 / 本轮假设
业务	查询制度、流程、公共资料及按员工权限开放的部门资料，回答附原文出处
资料源	现有NAS；员工已能访问各自获授权的目录 / 文件
身份与权限	保留NAS有效权限；NAS品牌、协议、AD / LDAP或独立账号体系待IT提供
部署地点	中国境内自有环境，沿用GPU采购研究的准确SKU与采购条件
文件类型	Word、PDF、PPT、Excel；包括扫描件、表格、图表及旧版Office格式
文件规模	用户尚不清楚。本轮计算示例为 10万文件、平均20片段 / 文件、200万片段
使用规模	50账号 为规划假设；分别计算1 / 5 / 20 / 30 / 50个同时到达的问答请求
问答负载	8,192输入tokens + 600输出tokens ，输入包含问题、指令、历史和检索片段
模型执行	FP8混合精度、文本问答、关闭思考输出和投机解码、前缀缓存命中率0；模型已加载
价格	人民币；GPU整机沿用9月21日预算，新CPU节点与实施量单列D估算


文件规模用于规划索引与入库；请求长度和到达方式用于规划在线服务。**50账号、50个活跃会话、50路同时生成**分别记录。例：50人每3分钟提交一次问题，每次占用30秒，平均进行中请求为 $50 \times 30 \div 180 \approx 8.3$ ；峰值另由突发测试衡量。

2. 两条路线的完整组成

层次	A: Onyx Enterprise	B: Milvus自建方案
员工入口	Onyx原生搜索与问答界面	Open WebUI；公司知识库请求路由至统一RAG服务
资料接入	Onyx连接器 + 纳入交付范围的NAS适配	自建NAS扫描 / 变更接入器
文件处理	原厂支持的解析、OCR与入库流程	Docling / Office解析器、OCR worker和任务队列
权限	Onyx企业权限体系 + NAS身份 / ACL映射	独立身份 / 权限服务，负责有效权限求值、更新与复核
检索与索引	使用所选Onyx版本原生支持的后端；本轮官方Helm sizing已采用OpenSearch	Milvus 2.6.x维护版本 ，向量 + BM25混合检索、标量过滤
Embedding / reranker	采用原厂支持的本地模型组合，验收中文资料 和延迟；指定Qwen模型时验证适配	Qwen3-Embedding-0.6B + Qwen3-Reranker-0.6B作为首轮基线
回答模型	自建vLLM OpenAI兼容端点；Qwen3.8-27B FP8	同左
管理与运维	原厂平台提供管理、索引作业、权限与审计，集成商承担约定接入	项目团队维护管理API、索引作业、权限同步、监控、升级及恢复


Onyx官方资料已覆盖私有化、自定义模型端点、企业组权限和指定连接器的源权限同步。**TECH-068** 本机构NAS尚未完成连接验证，因此**A的采购交付范围明确包含NAS连接、文件权限映射、撤权与引用访问测试**。Onyx原生支持SharePoint等资料源的事实，和该NAS适配的验收分别记录。

A路线的数据流



资料、身份、模型与工具之间的数据流；双向箭头表示请求与返回。

B路线的数据流



资料、身份、模型与工具之间的数据流；双向箭头表示请求与返回。

3. B路线：权限管理怎样开发

Milvus的RBAC管理实例、数据库和collection层面的操作；文件级权限由应用服务与检索过滤协同实现。Milvus支持检索前标量过滤、数组过滤和全文检索，可承载权限关联字段。[过滤检索](#)、[RBAC](#)、[数组操作](#)

3.1 五个开发模块

1. **身份映射。** 对接公司登录身份，将不可由客户端自行修改的用户标识映射到NAS账号、SID及有效用户组。目录服务存在嵌套组时完整解析；保持账号停用 / 调岗更新。
2. **权限采集与求值。** 保留共享目录和文件系统的权限、继承关系及版本；按实际NAS规则求有效读权限。NAS / Windows ACL包含的显式与继承条目，交由兼容的权限求值逻辑处理。
3. **权限关联索引。** 每个文档及其片段保存稳定doc_id、来源、版本、acl_policy_id、权限版本及页 / 表定位。相同权限的文件可共用policy，避免每条片段复制整份复杂ACL。
4. **统一查询鉴权。** 后端依据当前员工计算授权范围，为向量与BM25检索同时加入过滤条件；第一轮候选先返回内部ID和分数，经当前有效权限复核后才取正文、重排序并交给LLM。原文下载、引用和导出使用同一鉴权服务。
5. **更新与审计。** 内容变更更新对应片段和向量；权限变更更新policy与关联字段，撤销相关缓存。缓存按用户 / 有效授权范围及权限版本隔离；权限未取得或校验失败的候选保持不可用。

员工通过Open WebUI登录后，可信后端向RAG服务传递经验证的身份。Milvus凭据和源文件抓取权限只授予服务端组件，员工请求中的目录名、用户组或过滤表达式由后端验证和重建。Open WebUI的扩展 / Pipelines可作为调用接口，身份传递与鉴权属于本项目实现内容。[TECH-069](#)

3.2 NAS适配的交付与验收

按真实NAS确定文件协议、ACL读取方法和身份来源。读取文件、读取权限、按员工身份校验访问分别设接口。候选授权复核可通过NAS支持的权限检查或受信任身份委托完成；缺少在线校验能力时，需明确权限同步时限和失效策略，并将其列入验收。

验收至少包含：允许与拒绝的不同员工、嵌套组、继承与例外权限、文件移动、权限撤回、账号停用、直接调用检索API、引用下载及缓存命中。两个方案使用相同案例；以员工实际可读取的文件作为对照。

4. 文档处理、索引和模型

4.1 文件入库

格式	处理方式与保留信息
Word	解析标题层级、段落与表格；保存文档版本及段落定位
PDF	识别数字文本 / 扫描页，必要时OCR；保留阅读顺序、页码、表格、单位和脚注
PPT	按页提取标题、正文、表格与图表说明，保存页码；图像内容按需要调用视觉解析
Excel	按工作表与表格区域提取，保存表头、单位、单元格位置；公式和显示值分开记录
旧DOC / XLS / PPT	通过受控Office转换组件统一格式，再进入相应解析流程

Docling官方支持上述现代Office格式及PDF，旧二进制Office格式使用LibreOffice转换。[格式文档](#) 语义切分保留文档结构：正文分段、表格按完整表头和行块处理、PPT按页组织。跨表汇总和精确计算交给结构化查询 / 固定脚本；本场景主要交付证据查询与回答。

采用文件ID / 路径、修改标记、内容哈希及解析器版本判断变化；只为新增或内容变更片段重新计算embedding。权限变化更新授权元数据。失败作业保留原因和重试状态，删除和移动同步到索引与引用入口。

4.2 模型与精度

职责	本轮选择	资源 / 设置
效率对照	Qwen3.6-35B-A3B-FP8	官方激活约3B、全量权重仍驻留；按HF dtype元素数推导约37.455GB，预算向上取37.5GB
回答主候选	Qwen3.8-27B-FP8	稠密27B；同口径推导约30.864GB，预算向上取31GB
向量模型	Qwen3-Embedding-0.6B	1024维作为首轮索引设置；约0.596B BF16参数，tensor约1.192GB
重排序模型	Qwen3-Reranker-0.6B	候选片段与问题成对评分；同量级BF16参数

准确修订和官方原文见[TECH-070](#)。主模型FP8制品混有BF16层，不能直接把原BF16文件体量除以二。主模型独立Apache 2.0许可已归档；embedding / reranker模型卡声明Apache 2.0，独立LICENSE文件本轮未取得，采用资料据实记录。

容量模型按一次问答调用一次主回答模型计算。Onyx若启用问题改写、多步搜索或额外LLM判分，另按实际调用次数和token增加负载。

默认一次问答：关键词与向量各召回约50条，合并去重后授权复核，选择约20条重排序，约8条进入上下文。控制合计输入在8K附近；较长材料单独进入32K档。回答显式关闭thinking，生成预算600tokens，引用回到NAS文件及页 / 表位置。

4.3 入库与存储的数量级

10万文件×20片段=200万片段。1024维FP32向量的原始字节为2,000,000×1024×4=8.192GB。正文、标量 / 全文 / 向量索引结构、预览图、副本与备份另计，初始CPU节点按128GB内存和企业SSD配置。

若平均每片段512tokens，首次embedding约需处理10.24亿tokens。在8,000–32,000 tokens/s的纯假设吞吐下，embedding计算时间约8.9–35.6 GPU小时；这只是用于计划的敏感性例子，解析、OCR、NAS扫描、失败重试和索引写入另测。上线后的持续成本取决于每日变更量。在线embedding / reranker优先，批量OCR与重建安排独立队列和配额。

5. 四档共用硬件与购置预算

为公平比较A / B，采用相同回答模型和GPU配置。每档预留1张GPU承担embedding、reranker及受限速的文档处理；其余GPU各运行一个TP1回答模型副本。该划分避免把全部卡数都算成生成吞吐。新增模型副本提升并行请求能力，单个请求仍使用一张卡。

所有GPU服务器沿用9月21日已列CPU、主存、NVMe、网卡、供电和三年硬件支持BOM；价格为D分析预算。新增两台应用 / 检索CPU节点，每台16–32核x86、128GB ECC、2×3.84TB企业NVMe镜像、10 / 25GbE、冗余电源与基础硬件支持。

档位	GPU服务器	生成 / 辅助GPU	原GPU整机预算	加两台CPU节点后的硬件预算
H1	4×L20 48GB；512GB主存；90%基线采用27B FP8	3 / 1	40–74万元	52–100万元
H2	4×6000D 84GB；1TB主存	3 / 1	62–115万元	74–141万元
H3	8×6000D 84GB；2TB主存	7 / 1	109–200万元	121–226万元
H4	4×H200 NVL 141GB；1.5TB主存	3 / 1	169–345万元	181–371万元

来源：完整GPU服务器BOM及预算、价格数据。两台CPU节点是应用与数据角色分工；完整高可用的仲裁、存储副本和故障切换按所选SLA增加，本表不计新建机房、NAS扩容与持续运维。

CPU节点新增估价。每台硬件税前：128GB RAM 1.6–3.4万元，CPU / 平台 / 电源2.0–3.8万元，NVMe / 网络0.9–1.8万元，合计4.5–9.0万元。采用13%硬件税准备 + 10%价格准备 + 含税支持0.5–1.0万元，得到6.035–12.07万元，预算向外取整为6–13万元 / 台，D。RAM假设沿用既有价格模型，其余为本轮集成准备金，未取得准确OEM报价。

5.1 KV显存与总context容量

按每张回答卡计算：缓存池 = 显存×90% – 常驻权重 – 6GB运行时预留。KV与状态有效负载再乘1.15计入页块及对齐准备；辅助GPU用于embedding / reranker，其显存单独计量。回答模型权重为FP8混合精度，**KV统一为BF16 / FP16**。

- **35B-A3B**：10个全局注意力层，每token KV为20,480字节；每条驻留会话另需约64.39MB递归与卷积状态。
- **27B**：16个全局注意力层，每token KV为65,536字节；每条驻留会话另需约153.94MB递归与卷积状态。

两者均为全局注意力与线性注意力混合结构。本表保留一份活跃递归 / 卷积状态，按20条独立会话计算；实际引擎的状态检查点与物理页块分组在部署时核对。两个模型的原生单请求上限均为262,144tokens。[固定模型配置](#)

档位	回答模型	单卡 / 回答卡合计缓存池/GB	仅按显存可保留的总context/M	20路统一context配额/K
H1	35B-A3B	每卡预算不足0.3GB	—	—
H1	27B	6.2 / 18.6	0.197	9.216
H2	35B-A3B	32.1 / 96.3	4.025	191.488
H2	27B	38.6 / 115.8	1.487	70.656
H3	35B-A3B	32.1 / 224.7	9.476	262.144
H3	27B	38.6 / 270.2	3.535	168.192
H4	35B-A3B	83.4 / 250.2	10.557	262.144
H4	27B	89.9 / 269.7	3.529	167.936

K = 1,000、M = 1,000,000tokens；context包含输入、历史和生成结果。三副本将20路分成7 / 7 / 6，七副本分成3 / 3 / 3 / 3 / 3 / 3 / 2。最后一列以**最拥挤副本**决定所有用户的统一配额，并取模型上限；每个副本的缓存池独立使用。总context的显存预算与应用配置的单请求长度分别列出。

H2 / 35B示例：每卡缓存池为 $84 \times 90\% - 37.5 - 6 = 32.1$ GB，三卡合计96.3GB。按20路同时保留，每路统一预算191,488tokens，合计约3.830M；按各副本分别分配不同长度，上表显存总预算约4.025M。日常8,192输入 + 600输出的20路只需**5.62GB**，其中已计状态和15%缓存准备；27B同负载约需16.79GB。

L20的紧配边界：单卡35B权重37.5GB + 运行时6GB = 43.5GB，超过90%显存预算43.2GB，当前基线没有KV余量。95%显存利用率可留2.1GB缓存池，其独立测算见第6.5节。H1 / 27B在20路下每路约9,216tokens，8,192 + 600tokens工作负载可以放入，扩展上下文时需减少同时驻留请求。

因此，场景二保留8K日常输入和32K长资料对照即可。容量余量用于更多问答、较长引用和缓存；实际可服务并发由推理、检索 / 重排序及响应目标共同决定。

6. 响应时间与吞吐：计算结果

6.1 统一口径

- **Prefill总吞吐**：输入tokens总数÷有prefill活动的墙钟时间；20路无排队时，分母为最慢副本的输入处理时间。
- **Decode总速率**：各副本在同一时刻生成的输出token/s之和。下表20路均有共同生成的时间段；每路速度按其所在副本分别计算。
- **模型首token / 完整问答首token**：前者计模型排队与推理；后者再计身份、检索、重排序和网络。基准前置链路为0.8秒。
- **整段时间输出吞吐**：全部输出tokens÷从提问到整批回答完成的时间，计入prefill与检索。

所有结果为未实测校准的条件式估算。固定20路同时到达、每路8,192输入 / 600输出、冷缓存、模型已加载，关闭thinking和投机解码。内核效率与带宽利用率是第7节的待校准输入，工程假设和硬件规格分开记录。

6.2 20路问答：模型速度与用户等待时间

档位	模型	Prefill总吞吐/ 输入token/s	Decode总速率/ 输出token/s	每路 decode/token/s	完整问答末路 首token/秒	整批完成/秒	整段时间输出 token/s
H1	35B-A3B	—	—	—	—	—	90%显存预算不足
H2	35B-A3B	22,643	1,027	50.2–54.1	8.1	20.0	601
H3	35B-A3B	52,833	1,439	71.1–79.9	3.9	12.3	972
H4	35B-A3B	124,534	2,565	126.2–133.1	2.1	6.9	1,746
H1	27B	2,467	272	13.5–13.8	67.3	111.7	107
H2	27B	4,485	432	21.5–22.0	37.4	65.3	184
H3	27B	10,464	475	23.7–24.3	16.5	41.8	287
H4	27B	24,665	1,343	66.7–68.2	7.5	16.4	730

H2的三张回答卡运行独立模型副本，20路分为7 / 7 / 6。7路副本每路约50.2token/s，6路副本每路约54.1token/s，合计约1,027token/s。包含prefill的完整问答吞吐约601token/s，两个数字使用不同时间口径。

H2 / 35B推导：7路副本每步估计读取约14.19GB权重、KV、状态及其他数据，假设有效带宽838.8GB/s，内存时间约16.91ms；计算时间约0.97ms，再加3ms执行开销，每步约19.91ms，每路约50.2token/s。该副本prefill约7.24秒、decode约11.95秒，加0.8秒检索链路，总计19.98秒。20×600÷19.98约为601token/s。其模型首token约7.26秒，完整问答首token约8.06秒。

三副本开始和结束生成的时间略有差异；数据中另保留整个生成活动窗口的平均输出吞吐，本例约924token/s。主表的1,027指20路共同生成时的合计速率。实际压测同时采集每路时延和整段时间吞吐，以对应使用体验和服务容量。

6.3 H2 / 35B：并发变化

同时提交请求数	分到三副本的请求数	Decode总速率/token/s	每路 decode/token/s	末路首token/秒	整批完成/秒	整段时间输出 token/s
1	1 / 0 / 0	91	91.4	1.8	8.4	71
5	2 / 2 / 1	411	79.9–91.4	2.9	10.4	289
20	7 / 7 / 6	1,027	50.2–54.1	8.1	20.0	601
30	10 / 10 / 10	1,252	41.7	11.2	25.5	705
50	17 / 17 / 16	1,557	30.8–31.9	18.4	37.9	792

并发增加时，组批提高系统吞吐，每路生成速度及首token等待分别变化。三档效率参数下，H2 / 35B的20路整批完成约14.4–30.4秒；这些是参数敏感性情景。固定账号数用于估算请求到达率，例如50人每3分钟一问约16.7问 / 分钟，再按突发请求检验等待时间。

6.4 输入长度：日常问答与长资料

H2模型	每路输入tokens	20路末路首token/秒	20路整批完成/秒
27B	4,096	18.9	45.4
27B	8,192	37.4	65.3
27B	32,768	158.1	194.0
35B-A3B	4,096	4.3	15.8
35B-A3B	8,192	8.1	20.0
35B-A3B	32,768	37.5	51.9

在相同硬件下，35B-A3B的20路8K输入约20秒完成，32K输入约52秒；27B对应约65秒和194秒。日常RAG通过检索和重排序选择足够回答问题的片段，输入长度因此是响应时间的重要变量。这里比较相同输入 / 输出长度，回答质量由同一份问题与引用标准另行评估。

6.5 H1 / 35B的95%显存紧配对照

原版H1结果采用95%显存利用率。本次正文与场景三统一为90%，并补齐15%缓存开销和卷积状态；H1 / 35B的95%配置作为单独情景保留。在单卡2.1GB缓存池下，8K输入 / 600输出每批最多7路；20路整批约32.2秒、373输出token/s，50路经后续批次排队约81.7秒、367输出token/s。

这些结果适用于该显存配置及6GB运行时假设；容量统一保守按标称GB的十进制字节计算，H1边界对实际可见显存和运行时用量敏感，部署时由引擎内存分析确认。90%分析基线中的H1采用27B FP8，H2–H4继续比较27B与35B。

7. 性能模型、参数与适用范围

7.1 来源与工程假设

参数	L20	6000D	H200 NVL	性质
标称显存	48GB	84GB	141GB	厂商规格；本模型保守按每GB = 10^9 字节预算，上线以设备实际可见字节替换
标称显存带宽	864GB/s	1398GB/s	4800GB/s	HPE / NVIDIA规格
有效计算速率：低 / 基准 / 高	35 / 55 / 80 TFLOP/s	60 / 100 / 145 TFLOP/s	350 / 550 / 800 TFLOP/s	D 工程敏感性假设，未用目标设备实测校准；不是厂商峰值
带宽利用率：低 / 基准 / 高	45% / 60% / 75%	同左	同左	D假设

其他假设：MoE有效计算速率再乘0.60，覆盖专家调度和小矩阵效率；非主要矩阵计算的FLOPs准备系数1.15；每步固定开销稠密模型4 / 2 / 1ms、MoE 5 / 3 / 1.5ms；身份、检索、重排序和网络总延迟1.8 / 0.8 / 0.4秒，按各用户并行处理，前置服务吞吐需单独验收。每GPU运行时预留6GB，最多使用90%标称显存，KV与状态有效负载乘1.15计缓存开销，单副本批次上限32。H1 / 35B的95%配置单列敏感性结果。

本轮发现厂商 / 第三方表格存在dense与sparse峰值混用，6000D与标准96GB RTX PRO也有区别。因此计算显式使用有效计算速率作为待校准变量，并使用准确SKU的带宽；不能把另一款GPU的benchmark按卡名代入。方法参考JAX团队的Roofline和推理分析，原件见TECH-071。

以27B FP8的每步31GB读流量为例，先忽略KV和其他开销，标称带宽+31GB给出的模型内理想单路上限分别为**L20约27.9、6000D约45.1、H200约154.8 tokens/s**。加入KV / 状态流量、带宽利用率与执行开销后，单请求基准生成速度约16 / 25 / 76token/s，完整单请求指标保存在结果数据中。这一比较固定FP8和逐token生成方式。

7.2 主要公式

记输入长度为S、输出长度为0、单GPU批量为B、全局注意力层数为L、查询头数为Hq、头维度为D、激活参数为Pactive。

- 输入计算量：** $F_{\text{prefill}} \approx 2 \times P_{\text{active}} \times S \times 1.15 + 2 \times L \times H_q \times D \times S^2$ 。后项为因果全局注意力QK与AV。批量输入时间 $T_{\text{prefill}}(B) = B \times F_{\text{prefill}} / F_{\text{有效}}$ 。
- 稠密模型权重读流量：**每个生成步按31GB预算；一个批次可复用同一轮权重读取。
- MoE权重读流量：**假设各请求独立、均匀选择256专家中的8个，则被批次触及的专家比例 $u(B) = 1 - (1 - 8/256)^B$ ；每步权重流量 $W(B) = 5.3\text{GB} + 32.2\text{GB} \times u(B)$ 。32.2GB由40层、256专家、每专家三矩阵及FP8存储近似；5.3GB为非专家制品的保守读取准备。
- 每步生成时间：** $T_{\text{step}} = \max[(\text{权重} + \text{KV} + \text{线性注意力状态及其他读写流量}) / \text{有效带宽}, \text{生成计算量} / \text{有效算力}] + \text{固定开销}$ 。即对内存时间和计算时间取较大者后再加开销。
- 单次 / 同批响应：** $TTFT = T_{\text{检索}} + T_{\text{排队}} + T_{\text{prefill}} + T_{\text{step}}$ ； $T_{\text{完成}} = T_{\text{检索}} + T_{\text{排队}} + T_{\text{prefill}} + 0 \times T_{\text{step}}$ 。

6. **吞吐**：整批平均输出吞吐= $C \times 0$ / 整批完成时间；单副本持续混合服务能力 $B / (T_{\text{prefill}} + 0 \times T_{\text{step}})$ ，多副本分别相加后取70%作规划限流。

每请求KV按全局注意力层的 $2 \times \text{KV头数} \times \text{头维度} \times 2$ 字节计算：27B每token 65,536字节，35B每token 20,480字节；线性注意力递归状态按FP32、卷积状态按BF16预算，两者合计分别约153.94MB、64.39MB，每步计读写。驻留预算为 $[(S + 0) \times \text{KV字节} / \text{token} + \text{固定状态}] \times 1.15$ ；每副本准入请求数受可用缓存池及批次配置共同限制。

7.3 队列模型怎样解释

本轮采用便于审计的**分阶段批次**：一个批次先完成prefill，再生成答案；请求超过批次 / 显存上限时进入后续批次。它把突发拥塞明确计入，并没有模拟vLLM连续批处理的全部交错行为。连续批处理和chunked prefill可改善首次显示的分布，真实平台也可能出现额外竞争。

低负载首token、同到达最后首token、整批完成时间和规划每分钟请求数各有定义，不互相冒充。硬件规格能支持带宽 / 容量上限和条件式计算；有效算力、调度、检索尾延迟、专家分布及P95要在部署后校准。本文件提供的是可重算的预算模型。

8. 企业平台与自建方案的项目价格

8.1 H2基线：同硬件比较

成本项	A: Onyx Enterprise	B: Milvus自建
GPU + 两台CPU节点	74–141万元，D	74–141万元，D
首次实施与验收	42–68人天 $\times$ 2,500元 = 10.5–17万元，D	70–110人天 $\times$ 2,500元 = 17.5–27.5万元，D
软件	Onyx Enterprise私有化授权 / 支持报价记为L	开放组件按许可部署，未另计商业支持采购
首次购置 + 实施	84.5–158万元 + L	91.5–168.5万元

2,500元 / 人天是本研究的完整人天成本假设；工时为工程估算，非Onyx或供应商报价。A包含原厂安装、NAS / 身份权限适配、资料调优与共同验收；B增加RAG API、作业管理、权限与更新逻辑的开发。人天是投入量，项目日历还受人员并行与IT环境准备影响。

工作项	A人天，D	B人天，D
平台 / 运行环境	8	10–15
NAS、身份、权限映射与撤权	15–25	15–25
文档入库、解析与更新	5–10	10–15
检索调优、接口 / 入口、引用	6–10	10–15

工作项	A人天, D	B人天, D
验收、压力测试与权限测试	5-10	15-25
运维文档、备份恢复与交接	3-5	10-15
合计	42-68	70-110

Onyx官方价格页把私有化列入Enterprise并要求询价；公开Business云订阅不用于替代L。[官方价格](#) 做预算敏感性时，若**纯假设**第一年L=10 / 30 / 60万元，A对应首次投入为**94.5-168 / 114.5-188 / 144.5-218万元**。这三个授权值只是可替换变量，没有推断厂商成交价。

8.2 其他硬件档位

硬件档	硬件/万元	A首次购置实施/万元	B首次购置实施/万元
H1	52-100	62.5-117 + L	69.5-127.5
H2	74-141	84.5-158 + L	91.5-168.5
H3	121-226	131.5-243 + L	138.5-253.5
H4	181-371	191.5-388 + L	198.5-398.5

上述GPU估价已包含对应的税费、硬件价格准备和硬件支持，CPU节点也按相同方式估算，避免再重复加税或维护费。持续应用运维、用电、年度软件续费、NAS增容、机房和完整HA扩建进入后续TCO。现有四卡H200估价基于组件和集成假设，八卡HGX另有整机价格锚点；采购时按同一OEM、保修与许可交付口径询价。

9. 两条路线如何验收与交付

项目	两条路线的共同验收内容
权限	员工实际可读文件与检索、片段、引用、导出的结果一致；覆盖撤权与接口直接访问
文档质量	四类格式各取代表样本，核对页 / 表定位、标题、单位、表头、数字及版本
检索质量	固定问题集，标注正确文档 / 片段，检查召回、重排序与答案引用
回答质量	固定相同模型和生成预算，记录正确性、证据完整性、人工修改量
性能	4K / 8K / 32K输入、600输出；1 / 5 / 20 / 30 / 50并发；报告prefill、decode、每路速度、模型 / 完整问答TTFT、整段输出吞吐与请求率；实测统计P50 / P95

项目	两条路线的共同验收内容
资源与稳定性	每副本实际KV池、KV精度、状态和页块分配、目标context并发、峰值显存、CPU / SSD、OOM、重试、取消、入库干扰与权限同步延迟
运维	索引重建、文件更新 / 删除、模型升级回退、备份恢复、版本及数据流说明

采用vLLM的吞吐、TTFT、TPOT与goodput测量，再从前端测完整RAG响应。[benchmark文档](#) 同一硬件、相同模型服务下，平台间差异主要体现在资料接入、检索质量、权限、前置延迟和运维；本模型为两者统一使用0.4–1.8秒前置延迟情景，尚无两个平台的实测性能排名。

本轮完成边界：场景二的两条路线、开发分工、文件处理、模型、四档硬件、预算和响应 / 吞吐计算已形成文档。Onyx授权价、实际NAS身份与ACL接口、真实文件规模和目标设备效率作为可替换输入集中管理。后续讨论进入场景三，沿用本场景的授权检索接口与模型服务。

10. 数据、来源与复算

本次复算保留120组性能情景：105组满足当前内存预算，15组H1 / 35B标记为预算不满足；另列40组context容量、H2的输入长度对照及H1的95%显存情景。价格与平台方案沿用原输入。

- [假设与硬件 / 模型输入](#)
- [120组性能情景、40组context容量、长度 / 显存敏感性与预算](#)
- [计算脚本](#)
- [TECH-068：Onyx原文](#)
- [TECH-069：Milvus、NAS权限、前端与解析原文](#)
- [TECH-070：四个Qwen模型固定制品](#)
- [TECH-071：性能方法、GPU与引擎资料](#)

在仓库根目录执行：

```
python3 knowledge-base/infrastructure/data/scenario-2-rag-2026-09-23/calculate_capacity.py
```

来源保持原语言，提取文件和metadata记录URL、读取时间及SHA-256。研究与计算由主agent完成；本轮没有连接公司NAS、下载完整模型、安装平台、发出询价或执行GPU benchmark。正文中的算力效率、资料量及实施人天为显式分析输入。

文档整理：2026年9月24日。金额、精度与性能口径按正文；来源链接及完整计算数据随项目知识库保存。