

场景三：公司共享模型、通用工具链与通用Agent

日期：2026年9月23日 | 状态：方案设计、预算、模型推理与任务级性能估算。

本文件沿用场景二的结构，给出公司级通用Agent的完整组合。主线为**Hermes Agent + 公司共享模型服务 + 业务Skills / MCP工具 + 隔离执行环境**；现有NAS、员工身份及授权检索继续复用。文档比较集中执行和员工电脑执行两种形态，并按具体任务计算响应、吞吐、缓存与价格。

主部署口径：每个任务至少262,144总context，20个任务同时驻留并推理。 MiMo-V2.6 Flash / Pro继续使用发行者官方混合精度制品；Qwen个人 / 知识库模型的8-bit下限不套用于MiMo。以四卡H200 Flash为例，20任务时每任务的架构内存上限约566K；在实际使用262K、保留精确前缀并新增1K输入的测算中，每路生成约34token/s。

下文8K / 600及短任务轨迹保留为对应负载的历史对照。当前汇报使用第4.5节的长上下文预算及新测算文件，输入、输出和任务状态均纳入每任务context。

1. 业务用途与交付物

员工交给Agent一个目标和资料范围，Agent读取文件、查询资料、执行计算、检查结果，并交付可继续编辑的成果。三个贯穿例子如下：

任务	输入	Agent完成的工作	交付物
材料汇总	若干公告、制度或研究资料	查来源、比较差异、整理结构、补齐引用	简报、对照表、来源清单
财报与Excel比较	两期财报、Excel / CSV及口径说明	对齐期间和单位、计算指标、核对加总、解释变化	可编辑Excel、图表和文字说明
长程研究与报告	多份文件、研究问题及输出模板	多轮查证、分步分析、生成与检查图表、整合文稿	报告草稿、证据表和待人工判断的问题

场景二的授权检索作为工具返回资料片段与引用；本场景的Agent接续完成分析和文件处理。默认知识工具调用**检索接口**，不额外重复调用场景二的回答模型。结果进入用户 / 项目工作目录，业务人员复核后再纳入正式流程。


2. 两种执行形态

部分	集中执行：本轮主方案	员工电脑执行：轻量接入方案
使用入口	Hermes Desktop连接远程实例，或Open WebUI / 内网任务入口通过API接入	员工电脑上的Hermes Desktop / CLI
模型推理	公司共享vLLM / SGLang模型服务	同一公司共享模型服务
Agent状态	每用户 / 项目独立实例、配置、会话、记忆和工作目录	本机独立状态，公司统一分发模型与工具配置
文件 / 代码执行	服务器上的容器 / VM，集中调度CPU、内存和任务槽位	员工账号下的本机环境与已挂载NAS
公司工具	统一MCP / API服务，携带员工身份	同左；本机文件工具另外受员工操作系统权限控制
管理重点	任务队列、运行环境、并发、日志、产物及失败恢复	客户端分发、依赖一致性、终端管理及本机资源
适合工作	批量文件处理、较长任务、需要集中维护的工具	与个人当前目录、Office文件和日常操作紧密结合的任务

两种形态的LLM均在公司服务器运行。个人电脑承担模型推理的配置留给场景一。Hermes是这里的主讲harness；OpenClaw保留为渠道 / 设备接入对照，模型端点与MCP服务可以独立复用。

连接方式分别固定：**集中入口连接Hermes Agent API，工具在服务器执行；桌面方案在员工电脑运行Hermes，再连接共享vLLM模型API，工具在本机执行。** 这样可以直接沿用员工本机已授权的NAS访问，而服务器方案使用独立的身份与工具接入。

集中执行架构



资料、身份、模型与工具之间的数据流；双向箭头表示请求与返回。

产品已有能力与集成分工：Hermes已有Desktop、API Server、模型配置、Profiles、Skills、MCP及Docker / SSH工具后端，并提供[Open WebUI接入指南](#)。本项目建设公司身份路由、实例管理、任务配额、业务工具和成果交付；多用户入口按可信身份路由到独立实例，避免仅用一个共享API key区分所有员工。[TECH-072](#)

3. Harness、工具链与权限的具体组成

3.1 Hermes怎样部署

- 模型provider指向内部兼容端点，分别配置主模型、备用模型及辅助调用，统一记录实际路由。
- 每位员工 / 项目使用独立Hermes数据目录和进程；配置、会话、记忆及工具凭据按主体隔离。
- 集中工具运行在独立容器 / VM工作环境。Hermes的Docker终端后端默认是**每个Hermes进程一个持久容器**，跨工具调用保持文件和安装状态，因此公司隔离落实到实例和操作系统资源边界。
- 基线每实例同时执行一项任务，其他任务排队或分配独立实例；任务工作目录按ID隔离。容器创建由执行服务管理，任务环境不持有宿主机Docker控制权限。
- 组织共享Skills按版本发布；个人积累的方法和记忆保留在个人范围，进入共享目录前由维护者整理。
- 使用Hermes API提供任务状态、取消和会话接续；长期业务状态另外保存于任务服务，程序恢复时核对未完成的工具操作。

本轮官方文档还提供Managed Scope：管理员可固定模型端点等基线配置。它是配置管理机制；公司凭据、容器隔离和服务端授权由相应系统落实。Managed配置中使用非敏感参数，个人 / 任务凭据由独立凭据服务提供。[Docker](#)、[Profiles](#)、[API](#)、[Managed Scope](#)

3.2 六类工具与Skills

能力	MCP / 工具示例：接口为本项目设计	实现方式与返回内容
授权知识检索	search_knowledge、read_source	复用场景二，返回有权限的片段、来源ID及页 / 表定位
文件解析	parse_document、read_workbook	Docling / Office解析工具，返回结构化内容及文件位置
数据计算	run_analysis、 query_readonly_data	受控Python / SQL、固定公式和校验脚本；返回结果表、日志与异常
成果生成	write_workbook、render_report	使用模板生成Excel / Word / PPT / PDF，保存到任务工作目录
成果校验	validate_numbers、 check_citations、 render_preview	核对单位、期间、加总、引用及版面，必要时交回Agent修正
任务与交付	get_task_status、save_artifact	持久状态、产物版本、下载权限和完成通知

Skill保存业务方法，例如财报比较的期间、币种、公式和输出格式；MCP提供受权限控制的执行能力；固定脚本负责可重复计算。Word、Excel、图表与PDF预览依赖统一工具镜像和字体环境，避免每个任务重新安装组件。

3.3 复用NAS权限，并覆盖新增状态

任务入口确认员工身份，工具服务验证访问主体和scope。检索、NAS读取、成果保存及下载都沿用场景二的授权规则；员工账号停用、资料撤权或权限版本变化时，清理相关任务缓存或重建上下文。会话、记忆和产物记录来源及授权范围，避免通过共享Agent目录绕开文件权限。

模型只提出工具请求；权限由工具服务根据可信身份判断。凭据面向具体服务签发，资源服务器校验受众和scope；MCP授权设计参考官方协议。[授权与安全原文](#) 覆盖正式文件、对外发送或业务系统写入时，由业务工具提供对应预览与确认步骤；本轮任务容量只包含资料分析和草稿生成。

4. 模型与六个资源档

4.1 模型角色

模型	在本方案中的位置	固定资料与资源依据
Qwen3.6-35B-A3B FP8	复用现有资源、边界较清楚的任务与成本对照	沿用场景二制品，37.5GB权重预算，TP1
MiMo-V2.6-Flash-RL	通用Agent主容量模型	309B / 15B激活；主索引172.92GB，运行权重准备175GB；混合SWA / 全局注意力
MiMo-V2.6-Pro-RL	复杂任务的高能力对照	1.02T / 42B激活；主索引566.03GB，运行权重准备570GB；TP8参考路线
GLM-5.3-Flash、DeepSeek-V4.1-Flash	后续同任务质量 / 成本比较	沿用已有模型研究，分别固定精度、解析器和服务配置后计算

MiMo的存储为MXFP4专家与其他精度混合；模型卡的quant_method=fp8同时配有store_dtype=mxfp4。本轮关闭DFlash，不计入草稿加速收益，文本任务使用解析后的Office资料。多模态直接输入可在相同架构上另设样本。[MiMo专项](#)

9月23日vLLM recipe列出Flash的4×H200和4×MI325X路线，以及Pro的8×H200路线。专用镜像为mimo-v26；具体digest、量化内核、工具 / 推理解析器在实施时固定。当天recipe仍带有较早stable版本提示，版本判断沿用源码与镜像记录。新增AMD路径已归档，不覆盖9月22日旧快照。[TECH-074](#)

4.2 GPU资源与拓扑

档位	模型与GPU分配	主要用途	新增GPU整机预算 / 万元，D
A0	复用场景二四卡6000D中的1张，Qwen 35B单副本	小范围任务与成本基线	0
A1	新增4×6000D，一组MiMo Flash TP4，PCIe通信	成本优化的待验证组合	62–115
A2	新增4×H200 NVL，一组MiMo Flash TP4	主方案	169–345
A3	新增8×HGX H200，分两组MiMo Flash TP4	更多独立任务并行	290–352
A4	新增8×HGX H200，一组MiMo Pro TP8	更高能力模型	290–352
A5	新增8×MI325X，分两组MiMo Flash TP4	AMD并列资源方案	219–336

GPU整机CPU、主存、NVMe、网络、供电及支持范围，分别引用既有G3 / G5 / G6 / G7。[原BOM与价格](#)
H200 / MI325X的实际供货沿用该文准确SKU和许可交付条件。

资源计数：A1–A5的卡全部服务Agent主模型，检索辅助模型来自场景二已有资源。A0给Agent保留1张卡后，场景二回答副本从3个变为2个，需要重新分配问答容量。其余档位新增独立GPU服务，保留场景二原有回答资源。A1按容量与PCIe模型计算，精确SM120量化 / 注意力内核仍需验证；A2 / A4采用官方H200参考卡数。

4.3 每档硬件能留出多少缓存显存

先扣除常驻权重、引擎运行空间和设备余量，再分配KV与线性注意力状态。沿用原假设：使用90%标称显存；每卡预留6GB（Qwen） / 8GB（MiMo）给运行时；缓存有效负载之外另按15%准备页块和对齐开销。统一使用十进制GB。

缓存池 = 总显存×90% – 各副本权重合计 – 每卡运行时预留×卡数

KV与状态有效负载预算 = 缓存池÷1.15

档位	总显存/GB	各副本权重合计/GB	运行时预留/GB	缓存池合计/GB	KV与状态有效负载预算/GB
A0：1×6000D / Qwen35	84	37.5	6	32.1	27.91
A1：4×6000D / Flash	336	175	32	95.4	82.96
A2：4×H200 / Flash	564	175	32	300.6	261.39
A3：8×H200 / 两个Flash副本	1,128	350	64	601.2	522.78
A4：8×H200 / Pro	1,128	570	64	381.2	331.48
A5：8×MI325X / 两个Flash副本	2,048	350	64	1,429.2	1,242.78

A3的缓存池为两个独立的300.6GB池，A5为两个独立的714.6GB池；请求在所属副本内使用缓存。表中按TP内权重及KV均衡切分估算，额外的草稿模型和CPU offload未加入本配置。

4.4 缓存显存对应多少上下文tokens

本节统一采用BF16 / FP16 KV，每元素2字节。权重的FP8 / MXFP4与KV精度分开设置。一个context token表示会话中的一个位置，包含输入、历史和已生成输出；TP将其KV分片存储，token数按逻辑位置计一次。

模型	随历史增长的KV	每条驻留会话固定状态	当前原生单请求上限
Qwen35	10全局层×2 KV头×(256 + 256)×2 = 20,480字节/token	FP32递归状态62.91MB + BF16卷积状态1.47MB，合计64.39MB	262,144tokens
MiMo Flash	9全局层×4 KV头×(192 + 128)×2 = 23,040字节/token	39个滑窗层保留128tokens, 25.56MB	1,048,576tokens
MiMo Pro	10全局层×8 KV头×(192 + 128)×2 = 51,200字节/token	60个滑窗层保留128tokens, 39.32MB	1,048,576tokens

结构来自固定的Qwen FP8配置、MiMo Flash配置与MiMo Pro配置。本次容量计算补齐Qwen的卷积状态；先前性能计算中的62.91MB是递归状态部分。

对每个独立副本、其中的B条会话：

$$\text{每路内存容量} = (\text{缓存池字节} \div 1.15 \div B - \text{每路固定状态字节}) \div \text{每token KV字节}$$

结果向下取256tokens的规划粒度，再与模型单请求上限取较小值。下表固定**20条互不共享前缀的驻留会话**；双副本按10+10分配。K=1,000tokens，M=1,000,000tokens。

档位	仅按显存可保留的总context	20路平均的内存容量	加入模型上限后，每路context	20路可同时保留总context
A0	1.295M	64.768K	64.768K	1.295M
A1	3.574M	178.688K	178.688K	3.574M
A2	11.320M	566.016K	566.016K	11.320M
A3	22.666M	1,133.312K	1,048.576K	20.972M
A4	6.456M	322.816K	322.816K	6.456M
A5	53.914M	2,695.680K	1,048.576K	20.972M

这是按模型结构回收缓存的有效负载预算：Qwen每条活跃会话保留一份递归 / 卷积状态；MiMo滑窗层回收窗口外KV。vLLM的实际页块分组、padding以及保留额外前缀状态会影响物理容量；15%是规划余量，部署验收时需用各副本启动日志的KV token容量与目标长度并发数替换。框架按层类型分配及回收缓存的原理见 [vLLM Hybrid KV Cache Manager](#)。

MiMo滑窗回收的影响单列：若某个引擎配置将滑窗层也按完整历史分配，Flash每token需222,720字节、Pro需358,400字节。同样的硬件与20条会话，容量变为：

档位	滑窗KV按全长保留时，每路context	20路总context
A1	18.432K	0.369M
A2	58.624K	1.172M
A3	117.248K	2.345M
A4	46.080K	0.922M
A5	278.784K	5.576M

因此，MiMo部署配置需要同时固定模型版本、KV精度、滑窗回收及物理块容量。例如A2在两种缓存分配方式下，每路预算分别约566K和58.6K，差别远大于小幅调整显存利用率。

容量与调用预算衔接如下：A0若为每路输出保留8,192tokens，则输入与历史可用约56,576tokens；A2相同口径为557,824tokens。等待工具时保留的历史和其他会话的前缀同样占缓存池，需纳入驻留数量。较长上下文的首token与生成速度按对应长度重算，第7节8K测试的速度适用于该测试长度。5 / 20 / 30 / 50条驻留会话的完整结果见KV容量数据。

4.5 每个并发任务的长context预算

最低服务档为**262,144tokens / 任务**，总长度包括输入、历史和预留8,192输出。主表采用BF16 / FP16 KV，并要求滑窗层回收窗口外KV。每组TP副本的内存独立分配；下表是在给定驻留任务数下，每个任务可分配的相同context上限，已取模型原生上限。

配置	5任务	20任务	30任务	50任务
4×H200 / Flash TP4	1,048,576	566,016	376,832	225,792
8×H200 / 2组Flash TP4	1,048,576	1,048,576	755,200	452,608
8×H200 / Pro TP8	1,048,576	322,816	214,784	128,512
8×MI325X / 2组Flash TP4	1,048,576	1,048,576	1,048,576	1,048,576

20任务的Flash四卡、Flash八卡、Pro八卡方案均能分配至少262K。50任务时，四卡Flash和八卡Pro达不到每任务262K的本轮预算；两组Flash副本可继续满足。这里的任务数指同时保留完整上下文的任务；模型的活动请求上限和工具执行槽位另外设置。

当前调度最多32路 / 模型副本。262K档按内存和此调度限制共同计算，四卡Flash最多32路同时推理，两组Flash最多64路，八卡Pro最多24路。内存能够保留更多等待工具的任务时，也要记录这些驻留缓存占用。

20路、每任务262K的模型速度：warm1k命中252,928tokens前缀，新增1,024输入，随后生成8,192tokens。

配置	Prefill新增输入 token/s	Decode总token/s	每路token/s	热续跑首token/秒
4×H200 / Flash TP4	6,931	682	34.1	3.1
8×H200 / 2组Flash TP4	13,851	1,040	52.0	1.6
8×H200 / Pro TP8	5,045	553	27.7	4.2
8×MI325X / 2组Flash TP4	11,855	1,114	55.7	1.9

以上沿用硬件与效率假设，尚未实测校准。完整数据同时计算冷装载、524K档、5 / 20 / 30 / 50路和三档效率，先检查缓存及活动请求限制，再输出可行组合的速度。滑窗全长保留的容量对照也在数据中列出，用于核对引擎真实KV分配。

长context数据 · 复算脚本

5. CPU执行池与任务调度

集中执行新增两台CPU节点，每台16–32核x86、128GB ECC、2×3.84TB企业NVMe镜像、10 / 25GbE及冗余电源，预算**6–13万元 / 台**，沿用场景二估算。基线允许**8个重工具调用并行**，每个执行槽位按4vCPU / 8GB运行限额规划；轻量Agent进程和等待中的会话与重计算配额分别管理。

任务服务记录待执行→运行→等待工具 / 用户→完成 / 失败 / 取消，限制每用户活动任务、子任务数量、最大模型调用、总输出tokens及工具运行时间。NAS读取、表格处理与文件渲染使用不同任务类别和限额；浏览器任务作为后续扩展，可用独立浏览器容器池计价。

共享推理服务使用任务亲和路由，使同一任务继续落到相同模型副本，提高前缀复用。任务等待工具时可以让GPU处理别人的请求，但上下文缓存仍占显存。本轮模拟保留有限LRU缓存；空间不足时回收旧前缀，下次调用重新prefill。CPU KV offload另作优化项，当前没有计入恢复与转存收益。

6. 三类可重算的任务轨迹

以下是用于容量估算的**合成工作负载**，每种模型运行相同调用序列。真实模型的成功率、工具选择、重试次数和人工修改可能不同，最终比较同时记录任务质量与实际轨迹。

任务	模型调用	累计输入 tokens	累计输出 tokens	串行工具工作	峰值单次输入	轨迹说明
T1 材料汇总与简报	6	65,536	3,504	25秒	16,384	检索、读取、比较、生成与检查简报
T2 财报与Excel比较	10	210,944	7,680	101秒	32,768	数据读取、计算、口径校验、文件生成与说明
T3 长程研究与报告	18	792,576	20,480	275秒	75,776	多轮分析；包括1次压缩总结，第13轮重建上下文

累计输入指每轮提交给API的完整上下文总和；命中缓存的前缀仍属于逻辑输入，但只为未命中部分重新计算prefill。**输出**包括思考、工具调用参数和最终回复。Excel / 图表等文件通过工具生成，文件字节不按模型输出tokens等量计数。工具秒数为任务设计假设，不包括人工复核、外部系统停机或网络故障。

缓存与到达方式

- 每组1 / 5 / 20 / 50项任务在同一时刻提交，之后按真实先后依赖继续下一轮调用。
- 基准reuse70假设上一轮精确前缀的70%可复用，向下对齐到256tokens；初次请求、压缩后的新上下文及被LRU回收的前缀不命中。
- 冷缓存对照cold每轮重新处理完整上下文，不保留跨轮缓存。
- 每个模型副本FIFO组批，最多32个同时请求且受显存限制；先prefill该批，再逐步生成，短输出先完成，新调用进入后续批次。
- 8个工具槽位显式排队；子任务扩展通过额外轨迹计算，不把业务任务数直接等同于模型请求数。

7. 模型推理性能与Agent任务耗时

以下为未实测校准的分析估算。GPU带宽、权重和架构有来源；有效算力、通信、工具耗时和前缀可复用率为显式假设。先用固定长度请求比较模型服务，再用多轮任务计算完整产物耗时，两层分别计量。

7.1 短输入参考：prefill、decode与每路速度

指标口径

指标	计算口径	用途
Prefill阶段吞吐	未缓存输入tokens总数÷prefill阶段时间	模型处理提示词、文件与历史上下文的速度
Decode阶段系统吞吐	输出tokens总数÷decode阶段时间	所有正在生成的请求合计每秒输出多少tokens
每路decode速度	该请求输出tokens÷其生成时间；同长度、同速批次等于系统decode吞吐÷活动请求数	单个员工看到的模型生成速度；含思考及工具参数
TTFT / 首token时间	请求提交至模型首个输出token	包含排队、调度与prefill；首个输出可能是思考内容
完整请求时延	提交至该次模型调用全部输出完成	一次推理调用的等待时间
系统输出吞吐（整段时间）	所有输出tokens÷从提交到整批完成的时间	同时计入prefill、decode及服务调度，便于比较相同负载
系统总token吞吐（整段时间）	输入与输出tokens之和÷同一段时间	同时统计输入和输出的口径；需随表说明两者长度
请求吞吐	完成请求数÷同一段时间	req/s；这里是固定一批请求的折算值

系统吞吐需要写清统计哪些tokens、除以哪段时间。Prefill与decode使用同一组GPU，两个阶段吞吐分别描述处理输入和生成输出的能力。下表以“阶段吞吐”和“整段时间输出吞吐”明确区分。

20路同时推理：每路8K输入 / 600输出

所有请求同时到达，每路输入8,192、输出600tokens，无前缀命中，无先前排队；服务调度计0.15秒，不计客户端网络及工具执行。模型已加载。本表采用整批prefill后decode的统一近似，TTFT为该调度下的估算；实际continuous batching / chunked prefill会改变各请求的等待分布。

资源档与模型	Prefill总吞吐/输入token/s	Decode总吞吐/输出token/s	每路decode/token/s	首token/秒	每路完成/秒	整段时间输出吞吐/token/s
A0：1×6000D, Qwen35, TP1	7,925	560	28	20.9	42.2	284
A1：4×6000D, MiMo Flash, TP4	2,844	349	17	57.8	92.1	130

资源档与模型	Prefill总吞吐/输入token/s	Decode总吞吐/输出token/s	每路 decode/token/s	首token/秒	每路完成/秒	整段时间输出吞吐/token/s
A2: 4×H200, MiMo Flash, TP4	20,316	1,186	59	8.2	18.3	654
A3: 8×H200, MiMo Flash, 2组TP4	40,621	1,539	77	4.2	12.0	1,001
A4: 8×H200, MiMo Pro, TP8	11,690	936	47	14.2	27.0	445
A5: 8×MI325X, MiMo Flash, 2组TP4	35,064	1,584	79	4.8	12.4	968

A2的四张卡共同运行一个模型副本，20路请求在同一组卡上组批；A3 / A5的两个副本各处理10路。资源总吞吐已按对应副本数汇总。表内精度用于复算比较，实际性能随量化内核、拓扑和引擎调度校准。

A2的20路具体怎么算：

- 输入总量： $20 \times 8,192 = 163,840$ tokens；prefill约 $163,840 \div 20,316 = 8.06$ 秒。平均折算到每路约1,016输入token/s，这只是整批处理时间的分摊，不是固定的GPU配额。
- 生成每步约16.9ms，每步为20路各生成1token；系统约 $20 \div 0.0169 = 1,186$ token/s，每路约 $1,186 \div 20 = 59.3$ token/s。
- 每路生成600tokens约需 $600 \div 59.3 = 10.12$ 秒；加prefill与0.15秒服务调度，完成约 $8.06 + 10.12 + 0.15 = 18.33$ 秒；首token约8.23秒。
- 这批共输出12,000tokens，整段时间系统输出吞吐约 $12,000 \div 18.33 = 654$ token/s，请求吞吐约 $20 \div 18.33 = 1.09$ req/s。若统计输入加输出，则约9,590 token/s；与前两项使用不同分子。

并发与上下文怎样影响单个请求

A2同时推理请求数	Prefill总吞吐/输入token/s	Decode总吞吐/输出token/s	每路 decode/token/s	首token/秒	每路完成/秒
1	20,206	119	119	0.6	5.6
5	20,299	471	94	2.2	8.5
20	20,316	1,186	59	8.2	18.3
30	20,318	1,515	51	12.3	24.1

组批让不同请求共享权重读取和矩阵计算，增加并发会提高系统吞吐；每路速度则随共享计算、KV读取和通信开销变化。估算每路速度时，使用**当前并发下的系统decode吞吐÷当前正在decode的请求数**。上表1路119token/s、20路每路59token/s，体现了组批后的吞吐增长。不同长度请求、不同副本或调度优先级下，每路速度分别记录。

对长Agent还需固定上下文长度：A2同为20路 / 每路600输出，输入从8K增加到32K时，基准prefill吞吐约18,556输入token/s，每路decode约55token/s，首token约35.5秒，完成约46.3秒。沿用三档效率假设，8K / 20路每路decode为43–78token/s、首token6.3–11.7秒、完成14.0–25.7秒；这些是参数情景区间。

A0的560token/s怎样算出，证据到哪里

560token/s是20路合计的decode阶段推算值，每路约28token/s；计入prefill后整批输出吞吐约284token/s。目标6000D上的实测值目前为空。该数值保留用于检查公式，方案能力需要由同配置压测填写。

沿用20路、每路8,192输入 / 600输出，生成期间平均历史取8,492tokens。一次decode步给每路各生成1token：

计算项	原假设下的值与算法
专家集合覆盖率	每路从256专家选8个，独立均匀路由： $1 - (1 - 8/256)^{20} = 47.0\%$
每步权重读取	5.3GB非专家 + 32.2GB专家池 $\times 47.0\% = 20.44\text{GB}$ ；假设批次中同一专家权重有效读取一次
每步历史KV读取	$20 \times 8,492 \times 20,480 \text{ 字节} = 3.48\text{GB}$
递归状态读写 + 其他流量	$2.52 + 1.00 = 3.52\text{GB}$
每步合计流量	27.43GB
假设有效带宽	$1,398\text{GB/s} \times 60\% = 838.8\text{GB/s}$
内存 / 计算时间	内存约 32.70ms ，有效算力假设下计算约 2.76ms
每步时间	$\max(32.70, 2.76) + 3\text{ms 固定执行开销} = 35.70\text{ms}$
吞吐	总计 $20 \div 0.03570 \approx 560\text{token/s}$ ；每路 $1 \div 0.03570 \approx 28\text{token/s}$

这里最需要校准的是**60%有效带宽、跨请求专家权重复用、MoE小矩阵 / 反量化内核的效率，以及3ms固定执行开销**。简化公式使用计算与内存时间的较大值，并用固定开销合并其余执行成本；真实内核可能重复读取权重，路由和同步成本也会随批次变化。因此本次复核将560明确列为条件式计算值，未用它反向证明该硬件已经具备相应服务能力。

已有对照观察为**Qwen3.8-27B、4xA100 40GB、TP4，单请求约40token/s**，精度、长度和框架暂未记录。Qwen27是dense，A0的35B-A3B是MoE；该观察与A0的20路合计吞吐分别记录。TP4共同完成一个token的计算，收益取决于分片后计算量与通信开销，卡数本身不能决定单请求速度。[Qwen27官方结构](#)

公开测试也显示工作负载的重要性：Massed Compute自报单张RTX PRO 6000 96GB在Qwen35 BF16、FP8 KV、128输入 / 128输出、32并发时约**1,074输出token/s**；这是短提示的总输出吞吐。[原始测试](#) 另一位用户在vLLM 0.21 / 0.22、多模态PDF任务中，自报单张相关GPU约**72输出token/s**并提交性能问题。[原始问题与配置](#) 两者的硬件SKU、精度、上下文和调用方式均与A0不同，可用于检查量级及寻找瓶颈，A0校准仍需固定6000D、制品和8K / 600工作负载。

与“20项任务、6.4分钟”的关系

一项T2 Agent任务包括10次模型调用，20项任务合计200次调用、153,600个输出tokens，轮间还有工具执行。模型与工具按依赖交替运行，任一时刻处于decode的请求数会变化。模拟的整批时间380.7秒（6.35分钟），对应跨完整Agent流程的模型输出吞吐约403token/s；它使用更长的多轮输入，并把工具及排队时间一起计入分母。

因此，以下任务表回答“多久拿到最终文件”，本节模型表回答“当前并发下，每次推理多快、每路生成多快”。公司在线人数、活跃Agent任务数和同时推理请求数分别记录。

7.2 主方案A2：完整任务响应

本节及后续任务表的完成时间为同一批任务全部结束的时间；任务吞吐为这批任务数除以批次时间的小时折算值。

任务	同时提交任务数	首轮最后首token/秒	整批完成/分钟	整批折算任务/小时
T1	1	0.4	0.95	63
T1	5	1.2	1.18	254
T1	20	4.1	2.16	555
T1	50	17.9	4.10	732
T2	1	0.6	2.87	21
T2	5	2.2	3.47	87
T2	20	8.2	6.35	189
T2	50	30.9	12.97	231
T3	1	0.6	7.88	8
T3	5	2.2	10.11	30
T3	20	8.2	18.04	67
T3	50	41.3	37.72	80

“首轮最后首token”表示这一批任务中最晚开始模型输出的一项；模型输出可能先是思考或工具参数，入口的接单确认与任务进度另行显示。它与最终产物完成时间分别计量。

7.3 各资源档：20项任务同时提交

资源档	T1整批/分钟	T2整批/分钟	T3整批/分钟	T2折算任务/小时
A0	4.28	11.87	48.01	101
A1	8.31	21.46	78.37	56
A2	2.16	6.35	18.04	189
A3	1.81	5.48	14.54	219
A4	2.95	7.55	23.34	159
A5	1.84	5.56	14.67	216

A0的较短轨迹时间反映模型规模和单卡副本结构；固定轨迹不表示各模型能以相同成功率完成任务。A1受到较大的模型计算量及PCIe通信假设影响，应作为成本与延迟权衡的验证项。A3的双Flash副本侧重吞吐，A4将同样八卡资源用于Pro能力，两者不是单纯的速度升级关系。

7.4 较重负载：50项财报 / Excel任务

资源档	T2整批/分钟	折算任务/小时	模型组忙时占比	工具池忙时占比
A0	26.24	114	100%	40%
A1	44.14	68	100%	24%
A2	12.97	231	94%	81%
A3	11.89	252	76%	89%
A4	15.52	193	98%	68%
A5	12.08	248	75%	87%

A2与A3在该工具密集轨迹上的差距小于GPU数量差距，因为50×101=5,050槽位秒的工具工作，在8槽位下仅工具处理就需要至少约631秒（10.5分钟）。增加GPU后，CPU执行池、工具服务和任务组织会成为下一步扩展重点。

7.5 效率与缓存敏感性

资源档	20项T2完成区间/分钟	折算任务/小时区间
A0	9.03–17.20	70–133
A1	16.99–29.91	40–71
A2	5.39–7.83	153–223
A3	4.95–6.42	187–242
A4	6.66–9.72	123–180
A5	5.02–6.61	182–239

上表区间为三组效率参数的结果，不是置信区间。缓存对长任务的影响单独如下：

资源档	T3冷缓存整批/分钟	T3前缀复用整批/分钟	实际输入tokens命中率
A0	72.25	48.01	57%
A1	138.25	78.37	59%
A2	25.35	18.04	59%
A3	17.39	14.54	59%
A4	37.38	23.34	59%
A5	18.33	14.67	59%

A0在更高活动任务数和较长上下文下会频繁回收缓存；例如50项T3任务的基准模拟中，实际输入命中率约9%，完成约161分钟。该结果说明活跃任务与上下文驻留必须一起限制。A1–A5采用更大缓存池，但仍保留同样的显存上限与LRU规则。

7.6 并行子任务、工具槽位与思考预算

A2变化项	整批完成/分钟	工具池忙时占比
20项T2 / 8工具槽位	6.35	66%
20父任务×2条完整子轨迹	10.24	82%
20项T2 / 4工具槽位	9.34	90%
20项T2 / 16工具槽位	5.77	36%
20项T2 / 总输出预算翻倍	9.44	45%

“两条子任务”是20个父任务各派出两条完整T2轨迹的负载例子，共40条轨迹；父任务汇总还需增加调用，当前表只算子任务结束。输出预算翻倍时，后续输入同步增加新增历史tokens。该组计算展示：并行可以缩短有独立分工的关键路径，同时会增加调用和执行需求，调度需为子任务单独留配额。

8. 性能计算方法与参数

8.1 事件模型

对每项任务按轮执行：排队→模型prefill→生成→工具排队→工具执行→下一轮。模型批次内按每个请求实际输出长度结束；工具只在模型给出相应结果后开始。模拟同时保存每轮时间、输入、缓存、输出、GPU批次及工具排队，最终汇总完整产物耗时。

整体任务时间可理解为 $\Sigma(\text{模型等待} + \text{prefill} + \text{生成} + \text{工具等待} + \text{工具执行})$ ；并行子任务按依赖图取关键路径，资源忙时继续排队。长任务吞吐同时受模型服务和工具池约束。脚本另给出70%资源利用准备下的规划准入值，作为初始限流参考，不用它冒充实测P95或持续服务保证。

8.2 缓存与计算

若某轮完整输入长度为S、缓存前缀为K，主要投影计算近似为 $2 \times \text{激活参数} \times (S-K) \times 1.15$ ；因果全局注意力计算近似为 $L \times \text{查询头数} \times (\text{QK维度} + \text{V维度}) \times (S^2 - K^2)$ 。MiMo另计128-token滑窗的注意力计算。生成阶段仍读取完整历史KV，缓存命中不等于生成时的上下文消失。

MoE批次触及的专家比例仍采用 $u(B) = 1 - (1 - \text{top_k} / \text{专家数})^B$ 。Qwen沿用场景二的32.2GB专家池 + 5.3GB非专家流量预算；MiMo专家按MXFP4半字节权重及6.25%比例的块缩放存储近似，Flash专家池约160.86GB、Pro约531.35GB，剩余权重流量分别约14.14GB / 38.65GB。

每步时间取计算与显存访问两者的较大值，再加执行及跨GPU通信开销。TP的总带宽 / 算力乘卡数及并行效率系数；通信采用每层4次collective等价量、BF16激活和ring流量公式，并显式加入每次通信延迟。这个近似用于表示拓扑成本，尚未按真实内核与服务器拓扑校准。

8.3 硬件与效率输入

参数	6000D	H200	MI325X	性质
标称显存 / 带宽	84GB / 1398GB/s	141GB / 4800GB/s	256GB / 6000GB/s	既有硬件研究；容量保守按十进制字节计算
有效算力低 / 基准 / 高，TFLOP/s每卡	60 / 100 / 145	350 / 550 / 800	300 / 500 / 750	工程敏感性假设，非GPU厂商峰值
带宽利用率低 / 基准 / 高	45% / 60% / 75%	同左	同左	同场景二
Flash TP4并行效率：内存 / 计算	0.65 / 0.65	0.80 / 0.80	0.75 / 0.75	工程假设
等价链路带宽 / 单次延迟	24GB/s / 40μs	200GB/s / 12μs	180GB/s / 15μs	拓扑敏感性输入，非标称NVLink / Infinity Fabric峰值

Pro TP8的并行效率采用0.75。Qwen有效计算再乘0.60，MiMo乘0.55；MiMo低 / 基准 / 高固定执行开销为7 / 4 / 2ms每步，Qwen为5 / 3 / 1.5ms。HGX H200沿用H200 NVL的有效算力假设作同口径比较。主模型运行权重175 / 570GB已含舍入准备，未启用草稿；运行时另预留每GPU 8GB，Qwen为6GB。

缓存统一按两字节KV（FP16 / BF16）计算：MiMo Flash每个全局历史token约23,040字节，Pro约51,200字节；分别另有约25.56MB / 39.32MB滑窗缓存。Qwen沿用20,480字节 / token和约62.9MB递归状态。AMD官方recipe列FP8 KV，本表按两字节口径作保守比较，具体精度收益在质量确认后另算。预算再加15%页块等准备，显存使用上限90%；所有工具等待期间仍保留的前缀都进入LRU容量计算。

8.4 基线之后的优化次序

先固定可复现模型与引擎，核对工具调用及任务质量；再测前缀命中、回合数、输出token预算、工具批处理与CPU槽位。只有测到显存驻留压力时，再比较KV offload；它增加传输与恢复时间，需要与节省的prefill一起计量。投机解码、更加细致的prefill / decode调度及分离部署作为后续变体，基线不预支收益。[缓存与Serving原文](#)

9. 价格：新增投入和与场景二合并后的投入

本节采用已有**场景二H2硬件（74–141万元）**与**授权知识服务**的增量口径。A1–A5新增Agent专用GPU整机；A0复用1张生成卡。集中执行另加两台CPU执行节点12–26万元，桌面执行加一台工具 / 网关节点6–13万元并复用现有员工电脑。独立从零部署时，需加入场景二知识与权限底座，不能把该增量当全部费用。

9.1 集中执行

资源档	场景三新增硬件/万元	新增硬件 + 实施/万元	两场景合计硬件/万元
A0	12–26	32–61	86–167
A1	74–141	94–176	148–282
A2	181–371	201–406	255–512
A3	302–378	322–413	376–519
A4	302–378	322–413	376–519
A5	231–362	251–397	305–503

实施准备为80–140人天×2,500元 / 人天 = **20–35万元**，**D**：身份与实例 / 任务管理15–25人天、MCP与NAS授权工具20–35、文档 / 数据Skills及产物检查20–35、联调压测和运维交接25–45。人天是工程投入假设，不是供应商报价或日历工期。

“两场景合计硬件”只相加硬件，不重复计场景二的实施费和软件授权。平台维护、工具支持和特殊连接器按实际采购另列。既有Onyx授权若适用当前工具使用范围则复用，需要扩展授权时加入明确报价。

9.2 员工电脑执行

资源档	场景三新增硬件/万元	新增硬件 + 实施/万元
A0	6–13	18.5–35.5
A1	68–128	80.5–150.5
A2	175–358	187.5–380.5
A3	296–365	308.5–387.5
A4	296–365	308.5–387.5
A5	225–349	237.5–371.5

桌面执行实施准备为50–90人天×2,500元 = 12.5–22.5万元，**D**，覆盖客户端分发、依赖配置、模型 / MCP接入和产物验收。GPU推理预算与模型选择相同；工具性能改由实际员工电脑决定。第7节集中8槽位的工具时间不可直接作为所有员工电脑的性能。

软件核心按Hermes MIT及各模型 / 工具许可记录。米莫权重MIT声明、建模代码Apache 2.0与独立许可文件状态沿用既有专项。上述预算未计API数据订阅、付费网页 / 浏览器服务、新工作站、电费、专职运营人员及完整高可用改造。服务器税费与硬件支持已在原预算内，新增节点也采用含税准备口径。

10. 验收、运营与交付

维度	主要验收内容
最终产物	数字、公式、单位、引用、文件可编辑性及版面；按完整任务验收
工具链	工具成功率、失败恢复、固定脚本结果、重复执行的幂等性与产物版本
权限	NAS读取、检索、输出目录、下载、会话和记忆的主体隔离；覆盖撤权与恢复
响应	接单状态、首轮模型输出、首次工具进展、最终文件分别记录时间
模型服务	固定输入 / 输出长度与缓存命中，记录系统输入 / 输出吞吐、每路decode、TTFT及完整请求时延；实测另外统计P50 / P95
容量	分别记录在线人数、1 / 5 / 20 / 50活跃任务、同时推理请求数、输入 / 思考 / 输出tokens、工具排队与缓存占用
稳定性	取消、超时、任务重启、模型切换、容器清理、长期会话压缩与日志恢复
成本	每项合格任务的资源、重试、人工修订和服务成本，跨模型比较实际轨迹

主Agent可调用于任务，但公司调度为每项任务设调用与并行配额，避免一个长任务占满模型 / 工具池。模型升级时保持同一份任务集、工具版本和产物检查；技能和MCP接口的变化单独追踪。

本轮交付：第二套场景已形成部署形态、工具与权限设计、模型及六档资源、任务级性能模拟、增量 / 合并预算和验收方案。模拟中没有执行真实Agent、模型或公司文件；任务轨迹与效率输入集中保存，取得设备和任务样本后可替换校准。场景一随后讨论个人 / 小组本地模型与Coding Agent。

11. 数据与原始资料

- 任务、硬件、通信、缓存与价格假设
- 432组任务结果、逐轮轨迹、成本与敏感性
- 可复算事件模拟脚本
- 144组模型服务结果：8K / 32K、阶段吞吐及每路速度
- 模型服务指标复算
- 48组KV容量结果、模型上限与A0吞吐推导
- KV容量与A0吞吐复核计算
- TECH-072：Hermes部署、API、Skills与MCP
- TECH-073：MCP授权与安全规范
- TECH-074：MiMo新recipe与推理缓存

复算命令：

```
python3 knowledge-base/infrastructure/data/scenario-3-agent-2026-09-23/calculate_long_context.py
python3 knowledge-base/infrastructure/data/scenario-3-agent-2026-09-23/calculate_tasks.py
python3 knowledge-base/infrastructure/data/scenario-3-agent-2026-09-23/calculate_serving.py
python3 knowledge-base/infrastructure/data/scenario-3-agent-2026-09-23/calculate_kv_capacity.py
```

原件保持原语言，来源URL、时间及SHA-256见各来源metadata。计算由主agent完成，用户人工及目标设备实测校准尚未进行。本轮未连接NAS、安装Agent服务、发送消息、购买服务或改变第一套方案的历史计算。

文档整理：2026年9月24日。金额、精度与性能口径按正文；来源链接及完整计算数据随项目知识库保存。